



武汉大学
WUHAN UNIVERSITY

第3讲 线性模型

2025~2026学年

授课老师：《机器学习》课程组

《机器学习》



1 线性回归的基本模型

何为线性模型？

- **线性回归 (linear regression)** 是机器学习中预测数值型数据的最基础的方法。其目的是从样本中学习一个线性模型 $g(\mathbf{x})$ 去表征自变量（解释变量）和因变量（响应变量）之间的关系
- 简单线性回归：仅有一个自变量（样本特征）和一个响应变量（样本标记），二者之间的关系可以用一条直线近似表示
- 多元线性回归：有两个或两个以上的特征，且特征和标记之间是线性关系。当特征维数为2时，线性模型是一个平面。当特征维数为3时，线性模型是一个立方体。以此类推，在高维空间中是一个超平面
- 多响应变量回归：用于分析多个响应变量与特征之间的关系，可以看作是单响应变量回归的扩展



回顾：高考数学的线性回归题

例 1. 某 5 名学生的总成绩和数学成绩（单位：分）如下表所示：

学生	A	B	C	D	E
总成绩 (x)	482	383	421	364	362
数学成绩 (y)	78	65	71	64	61

(1) 求数学成绩 y 对总成绩 x 的回归方程；

(2) 如果一个学生的总成绩为 450 分，试预测这个学生的数学成绩。

【解】 (1) 根据表中数据可得， $\bar{x} = \frac{2012}{5}$ ， $\bar{y} = \frac{339}{5}$ 。

$$\text{所以 } \hat{b} = \frac{\sum_{i=1}^5 x_i y_i - 5 \bar{x} \bar{y}}{\sum_{i=1}^5 x_i^2 - 5 \bar{x}^2} = \frac{137760 - 5 \times \frac{2012}{5} \times \frac{339}{5}}{819794 - 5 \times \left(\frac{2012}{5}\right)^2} \approx 0.132,$$

$$\hat{a} = \bar{y} - \hat{b} \bar{x} \approx \frac{339}{5} - 0.132 \times \frac{2012}{5} \approx 14.683.$$

所以回归方程为 $\hat{y} = 0.132x + 14.683$ 。

(2) 当 $x = 450$ 时， $\hat{y} \approx 74$ 。

即当一个学生的总成绩为 450 分时，他的数学成绩约为 74 分。

【点评】解决这类问题，要准确理解公式中每部分表示的意义，正确代入数据并认真计算。注意求得回归方程的书写形式，如本题，要写成 $\hat{y} = 0.132x + 14.683$ ，而不能写成 $y = 0.132x + 14.683$ ，因为求出的函数值是估计值，而不是精确值。

- 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, 样本空间由 d 维向量张成, $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})^T, y_i \in \mathbb{R}$, 则:

- 线性回归方程为:

$$\hat{y}_i = g(\mathbf{x}_i) = w_1 x_{i1} + w_2 x_{i2} + \dots + w_d x_{id} + w_0$$

写为向量形式:

$$\hat{y}_i = g(\mathbf{x}_i) = \mathbf{x}_i^T \mathbf{w} + w_0,$$

其中 $\hat{y}_i$ 是回归预测值, $\mathbf{w} = (w_1, \dots, w_d)^T$ 和 w_0 是模型的参数



m 是样本个数, d 是样本维数。一定要区分开!

2 线性回归的学习准则

- 损失函数：定义在单样本上
- 代价函数：定义在全体样本上

➤ 一般采用MSE作为代价函数（Cost）。当回归预测值与样本标记值具有最小均方误差时获得最优参数

均方误差（Mean-Square Error, MSE）：

$$MSE = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$$

增广1维 →

$$\mathbf{w} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_d \\ w_0 \end{bmatrix} \quad \mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}$$

特征权重（参数） 样本特征属性值 样本标记值



➤ 最小化MSE，求解最优参数

- 最小化代价函数：

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} \sum_{i=1}^m (\hat{y}_i - y_i)^2$$

- 写成向量形式：

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})$$

3 线性回归的优化算法

➤ 用常最小二乘法 (Ordinary least squares) 求解最优参数:

最小二乘法

$$\text{令 } L(\mathbf{w}) = (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})$$

← 平方误差代价函数

$$\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}} = 2\mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = 0$$

← 求驻点

$$\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

可求得: $\hat{y}_i = g(\mathbf{x}_i) = \mathbf{x}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$



➤ 向量求导在机器学习中经常遇到

设 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)^T$, $\beta = (\beta_1, \beta_2, \dots, \beta_m)^T$, 则:

$$\frac{\partial \beta^T}{\partial \alpha} = \left(\frac{\partial \beta_1}{\partial \alpha}, \frac{\partial \beta_2}{\partial \alpha}, \dots, \frac{\partial \beta_m}{\partial \alpha} \right) = \begin{bmatrix} \frac{\partial \beta_1}{\partial \alpha_1} & \frac{\partial \beta_1}{\partial \alpha_2} & \dots & \frac{\partial \beta_1}{\partial \alpha_n} \\ \frac{\partial \beta_2}{\partial \alpha_1} & \frac{\partial \beta_2}{\partial \alpha_2} & \dots & \frac{\partial \beta_2}{\partial \alpha_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \beta_m}{\partial \alpha_1} & \frac{\partial \beta_m}{\partial \alpha_2} & \dots & \frac{\partial \beta_m}{\partial \alpha_n} \end{bmatrix}_{n \times m} \quad \frac{\partial \beta}{\partial \alpha^T} = \left(\frac{\partial \beta_1}{\partial \alpha^T}, \frac{\partial \beta_2}{\partial \alpha^T}, \dots, \frac{\partial \beta_m}{\partial \alpha^T} \right)^T = \begin{bmatrix} \frac{\partial \beta_1}{\partial \alpha_1} & \frac{\partial \beta_1}{\partial \alpha_2} & \dots & \frac{\partial \beta_1}{\partial \alpha_n} \\ \frac{\partial \beta_2}{\partial \alpha_1} & \frac{\partial \beta_2}{\partial \alpha_2} & \dots & \frac{\partial \beta_2}{\partial \alpha_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \beta_m}{\partial \alpha_1} & \frac{\partial \beta_m}{\partial \alpha_2} & \dots & \frac{\partial \beta_m}{\partial \alpha_n} \end{bmatrix}_{m \times n}$$

即: $\frac{\partial \beta^T}{\partial \alpha} = \left(\frac{\partial \beta}{\partial \alpha} \right)^T$

一般行向量对列向量求导, 列向量对行向量求导

但很多时候为了简单起见, 会直接写为 $\frac{\partial \beta}{\partial \alpha}$



➤ 设 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)^T$, $f(\alpha) = (\beta_1, \beta_2, \dots, \beta_m)^T$, $g(\alpha) = (\gamma_1, \gamma_2, \dots, \gamma_m)^T$

$$h(f(\alpha)) = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_k)^T$$

则向量求导的基本法则:

$$\frac{\partial(\lambda f(\alpha) + \mu g(\alpha))^T}{\partial \alpha} = \lambda \frac{\partial f(\alpha)^T}{\partial \alpha} + \mu \frac{\partial g(\alpha)^T}{\partial \alpha}$$

$$\frac{\partial f(\alpha)^T g(\alpha)}{\partial \alpha} = \frac{\partial f(\alpha)^T}{\partial \alpha} g(\alpha) + \frac{\partial g(\alpha)^T}{\partial \alpha} f(\alpha)$$

$$\frac{\partial h(f(\alpha))^T}{\partial \alpha} = \frac{\partial f(\alpha)^T}{\partial \alpha} \cdot \frac{\partial h(f(\alpha))^T}{\partial f(\alpha)}$$

 $n \times k$ $n \times m$ $m \times k$

(向量求导链式法则)

➤ 设 $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_n)^T$, A 为 $n \times m$ 矩阵, 则:

$$\frac{\partial \alpha^T A}{\partial \alpha} = A, \quad \frac{\partial \alpha^T A \alpha}{\partial \alpha} = (A + A^T) \alpha, \quad \frac{\partial \alpha^T \alpha}{\partial \alpha} = 2\alpha$$

➤ 所以在最小二乘中:

$$\begin{aligned} \frac{\partial (y - Xw)^T (y - Xw)}{\partial w} &= \frac{\partial (y - Xw)^T}{\partial w} \cdot \frac{\partial (y - Xw)^T (y - Xw)}{\partial (y - Xw)} \\ &= -X^T \cdot 2(y - Xw) = 2X^T (Xw - y) \end{aligned}$$

证明 $\frac{\partial \alpha^T A}{\partial \alpha} = A$ 留作课后思考题



➤ 若 $X^T X$ 为满秩矩阵, 则 $(X^T X)^{-1}$ 可求, 最优参数 w^* 可直接解出:

$$w^* = (X^T X)^{-1} X^T y$$

闭式解 closed-form



在机器学习中, 往往会遇到样本维数远大于样本个数 ($d > m$) 的情况, 比如图像或某种高分子样本等, 则 $X^T X$ 必不满秩:

- 如果 $d > m$, 则 X 是一个行数小于列数的矩阵 (线性方程组的个数少于未知数的个数), 则 X 必不满秩
- 根据矩阵秩的性质: $\text{rank}(AB) \leq \min(\text{rank}(A), \text{rank}(B))$


$X^T X$ 是一个方阵, 但不满秩

- 若 $X^T X$ 不可逆，可采用**梯度下降法**（Gradient descent）训练参数：

梯度下降法

- 确定代价函数： $L(\mathbf{w}) = \frac{1}{2m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$ 为了求导方便
- 计算当前参数下代价函数的梯度。梯度是一个向量，其各分量表示代价函数对各个参数 w 的偏导数。梯度的方向代表函数值增加最快的方向，因此**负梯度方向**就是代价函数减少最快的方向
- 确定学习率 η （步长），根据步长沿着代价函数负梯度的方向迭代搜索，找到一个函数极值

$$\mathbf{w}^{(i+1)} \leftarrow \mathbf{w}^{(i)} - \eta \cdot \frac{\partial L(\mathbf{w}^{(i)})}{\partial \mathbf{w}^{(i)}}$$





$$\mathbf{w}^{(i+1)} \leftarrow \mathbf{w}^{(i)} - \eta \cdot \frac{\partial L(\mathbf{w}^{(i)})}{\partial \mathbf{w}^{(i)}}$$

← 上标(i)表示第 i 次迭代，每一次迭代都会更新一组参数 $\mathbf{w}$ ，从而得到一个新的损失 $L(\mathbf{w})$

$$\nabla L(\mathbf{w}) = \begin{pmatrix} \frac{\partial L}{\partial w_1} \\ \vdots \\ \frac{\partial L}{\partial w_d} \\ \frac{\partial L}{\partial w_0} \end{pmatrix} :$$

η :

梯度：是一个 $d+1$ 维向量(含对偏置参数 w_0 的偏导)，是函数变化最快的方向（负梯度：比喻为下山最快的方向）

学习率：每次更新参数的幅度。比喻为下山的步长。注意，学习率不一定是常数，是可以根据梯度下降情况而动态变化的

→第九讲



4 线性回归的正则化

- 岭回归 (Ridge regression) 和套索回归 (Lasso regression) 是带有**正则化 (regularization)** 的线性回归
- 正则化是通过对代价函数加以限制, **防止模型过拟合的重要方法**, 是结构风险最小化思想的一种具体体现, 在机器学习中非常有用。
- 在线性回归中一般会对参数和 (体现为L1范数或L2范数) 加以限制, 使得最优化时既让代价函数最小, 又满足参数限制条件。在多项式回归中, 则一般会对高次项的参数加以限制

- 岭回归在线性回归代价函数上添加了L2正则化项：

$$L(\mathbf{w}) = \frac{1}{2m} \left[\sum_{i=1}^m (\hat{y}_i - y_i)^2 + \lambda \sum_{j=1}^d w_j^2 \right] \quad (w_0 \text{不惩罚})$$

正则化系数

$\mathbf{w}$ 的L2范数的平方: $\|\mathbf{w}\|_2^2$

- 岭回归代价函数最小二乘优化的闭式解：

$$\mathbf{w}^* = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

$\mathbf{I} = \begin{bmatrix} 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1 \end{bmatrix}$ 是一个单位矩阵，保证了 $(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})$ 可逆， $\mathbf{w}$ 具有闭式解

- 岭回归代价函数的梯度下降迭代:

对第 k 个特征的参数 w_k :

$$w_k^{(i+1)} \leftarrow w_k^{(i)} - \eta \cdot \left(\frac{\partial L(\mathbf{w})}{\partial w_k^{(i)}} + \frac{\lambda}{m} w_k^{(i)} \right)$$

- 岭回归正则化系数 λ 是一个对参数 $\mathbf{w}$ 的惩罚系数:

- 从 $L(\mathbf{w})$ 的角度看: 若 λ 系数很大则要使得 $L(\mathbf{w})$ 最小, 必须减小 $\mathbf{w}$ 。即惩罚 $\mathbf{w}$, 降低各特征的权重系数。 λ 过大会使得 $\mathbf{w} \rightarrow [0, 0, \dots, 0]$, 模型会欠拟合
- 通过引入 λ 来限制了所有 w_k 之和, 通过惩罚降低不重要的那些特征的权重, 从而实现模型的结构风险最小化

提问: 既然岭回归有闭式解, 为什么还要用梯度下降法求参数?




7 广义线性回归

- 广义线性回归 (Generalized Linear Regression, GLM) 是传统的线性回归的一种普遍拓展。其核心思想是通过某个联系函数, 将线性回归的输出值映射成不同的分布
- 广义线性回归常用来处理标记空间 Y 具有指数族分布 (exponential dispersion family) 的非线性回归问题。正态分布、泊松分布、二项分布、伽马分布、贝塔分布都属于指数族分布, 其概率密度可以写成含有参数的指数形式

- 假设样本所对应的输出标记是在指数尺度上变化，可将输出标记的对数作为线性模型，构建回归方程

令 $y' = \ln y = \mathbf{x}^T \mathbf{w} + w_0$ ，实际是在用 $e^{\mathbf{x}^T \mathbf{w} + w_0}$ 逼近 y

- 在学习样本空间到标记空间的非线性函数映射过程中，对数函数起到了将线性回归的预测值与非线性的真实标记联系起来的作用





➤ 因此可以得到广义线性回归的基本形式：

$$\hat{y}_i = \sigma(z_i) = \sigma(\mathbf{x}_i^T \mathbf{w} + w_0)$$

其中， $\sigma()$ 是单调可微的**联系函数**（link function），也称**激活函数**

8 多项式回归

- 多项式回归 (Polynomial Regression) 是一种线性回归模型的推广。其中自变量 (解释变量) 和因变量 (响应变量) 之间的关系被建模为 n 次多项式
- 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, 样本空间由 d 维向量张成, $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})^T, y_i \in \mathbb{R}$, 则:

多项式回归方程为:

$$\hat{y}_i = g(\mathbf{x}_i) = w_0 + w_{11} x_{i1} + w_{12} x_{i2} + \dots + w_{1d} x_{id} + w_{21} x_{i1}^2 + \dots + w_n x_{i1} x_{i2} + \dots$$

偏置参数

一次项

高次项

交互项



➤ 对于非线性回归，增加高次项可以提高模型的拟合能力。但也要注意“过拟合”问题

- 高等数学的角度：任何复杂的函数 $f(x)$ 在点 $x=a$ 处具有任意阶导数，那么该函数可以在点 $x=a$ 处展开为如下形式的无穷级数

$$f(x) = f(a) + f'(a)(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \cdots + \frac{f^n(a)}{n!}(x-a)^n + \cdots$$

- 机器学习的角度：增加了高次项，就是增加了样本特征，从而提高了模型复杂度，提高模式识别能力

- 多项式回归可以等价于线性回归进行计算：通过一组**基函数** $\phi(x)$ 将 d 维（低维）的样本，映射到 n 维（高维）空间中，使得低维多项式回归等价于高维线性回归

$$g(x) = [\phi_i(x)]^T \mathbf{w} + w_0 \quad i=1, 2, \dots, n$$



• 幂函数基函数

比如为一维样本空间的样本 x_i 构造3个基函数： $x_i \xrightarrow{\phi(x)} \mathbf{z}_i = \begin{pmatrix} z_{i1} \\ z_{i2} \\ z_{i3} \end{pmatrix}$

$$z_{i1} = \phi_1(x_i) = x_i, \quad z_{i2} = \phi_2(x_i) = x_i^2, \quad z_{i3} = \phi_3(x_i) = x_i^3$$

$$\text{则: } y_i = w_1 x_i + w_2 x_i^2 + w_3 x_i^3$$

← 一维空间多项式回归

$$\Rightarrow y'_i = w_1 z_{i1} + w_2 z_{i2} + w_3 z_{i3}$$

← 三维空间线性回归



- 乘积项 (product term) 基函数

比如样本空间 $X=(x^{(1)}, x^{(2)})$ 是一个二维空间，构造5个基函数：

$$z_{i1} = \phi_1(x_i) = x_{i1}, \quad \phi_2(x_i) = x_{i2}, \quad \phi_3(x_i) = x_{i1}^2, \quad \phi_4(x_i) = x_{i2}^2, \quad \phi_5(x_i) = x_{i1}x_{i2}$$

则： $y_i = w_1x_{i1} + w_2x_{i2} + w_3x_{i1}^2 + w_4x_{i2}^2 + w_5x_{i1}x_{i2}$ ← 二维空间非线性回归

$\Rightarrow y'_i = w_1z_{i1} + w_2z_{i2} + w_3z_{i3} + w_4z_{i4} + w_5z_{i5}$ ← 五维空间线性回归

- 基函数 $\phi(x)$ 方法降低了回归模型复杂度，是一种将线性模型推广到非线性模型的代表性方法。但这种方法升高了样本空间的维数，且需要知道基函数 $\phi(x)$ 的具体形式，需要引入“核方法”对其进行进一步完善



9

模型小结


模型	策略（准则）	算法
$y = g(\mathbf{x}) = \mathbf{x}^T \mathbf{w} + w_0$ • 核心参数： 特征权向量 $\mathbf{w}$	• 最小均方误差MSE： $\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} \frac{1}{2m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$	• 最小二乘法： $\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ • 梯度下降法： $\mathbf{w}^{(i+1)} \leftarrow \mathbf{w}^{(i)} - \eta \cdot \frac{\partial L(\mathbf{w}^{(i)})}{\partial \mathbf{w}^{(i)}}$

线性可分概念与线性分类算法

一个分类问题是否属于**线性可分**，取决于是否有可能找到一个点、直线、平面或超平面来分离两个相邻的类别。

如果每个类别样本的分布范围本身是全连通的单一凸集，且互不重叠，则这两个类别一定是线性可分的，如图所示。

线性分类算法主要有线性判别函数、Fisher判别分析、单层感知器、逻辑回归等。



线性可分情况

直接用来对模式进行分类的决策函数。

若分属于 ω_1 , ω_2 两类的 n 维模式在空间中的分布区域, 可以用一代数方程 $d(X) = 0$ 决定的超平面作为分隔面, 两类样本分布在分隔面的两侧, 那么就称 $d(X)$ 为判别函数, 或称决策函数。代数方程 $d(X) = 0$ 表示的是 n 维空间的 $(n-1)$ 维判决面 (或超平面或超曲面, 视 $d(x)$ 形式而定)。





图3.2 两类二维模式的分布

例: 一个二维的两类判别问题, 模式分布如图示, 这些分属于 ω_1 , ω_2 两类的模式可用平面中的直线 $d(X)=0$ 来划分。

$$d(X) = w_1 x_1 + w_2 x_2 + w_3 = 0$$

式中: x_1, x_2 为坐标变量,

w_1, w_2, w_3 为方程参数。



示例：线性判别函数（维数为2）。

将某一未知模式 X 代入：

$$d(X) = w_1x_1 + w_2x_2 + w_3$$

若 $d(X) > 0$ ，则 $X \in \omega_1$ 类；

若 $d(X) < 0$ ，则 $X \in \omega_2$ 类；

若 $d(X) = 0$ ，则 $X \in \omega_1$ 或 $X \in \omega_2$

或：拒绝分类

特征维数=3时：判别面为三维空间中的平面。


特征维数>3时：判别面为高维空间中的超平面。

注：为了清晰地了解 $d(x)$ 的含义，应该画出**判别函数值 $d(x)$ 这一轴**，在没有画出的时候，就在自变量（模式）空间中画出 $d(x)$ 取正负值的区域——这就是所谓**判别面的正侧、负侧**。

判别面的正负侧，是在训练判别函数的权值时**人为设定的**。但是一旦设定后，训练好的模型（分隔面）的正负侧就是确定的，而且由判别函数的梯度矢量确定。

一般，令第1类样本的函数值大于零，第2类样本的函数值小于零。也就是说，类别标号值为{1, -1}。也有用{1,0}表示正负类的。

具体值的大小不重要，主要便于算法公式的简洁（后面会讲到）。





(一) 线性判别函数的一般形式

将二维模式推广到 n 维, 线性判别函数的一般形式为:

$$d(X) = w_1x_1 + w_2x_2 + \dots + w_nx_n + w_{n+1} = \mathbf{W}_0^T \mathbf{X} + w_{n+1} \quad (3-2)$$

式中: $\mathbf{X} = [x_1, x_2, \dots, x_n]^T$

$\mathbf{W}_0 = [w_1, w_2, \dots, w_n]^T$: 权向量, 即参数向量。

增广向量形式:

$$d(X) = w_1x_1 + w_2x_2 + \dots + w_nx_n + w_{n+1} \cdot 1$$

$$= \begin{bmatrix} w_1 & w_2 & \dots & w_n & w_{n+1} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \\ 1 \end{bmatrix} = \mathbf{W}^T \mathbf{X}$$

式中:

$$\mathbf{X} = [x_1, x_2, \dots, x_n, 1]^T$$

为增广模式向量。

$$\mathbf{W} = [w_1, w_2, \dots, w_n, w_{n+1}]^T$$

为增广权向量,



1. 两类情况

$$d(\mathbf{X}) = \mathbf{W}^T \mathbf{X} \begin{cases} > 0, & \text{若 } \mathbf{X} \in \omega_1 \\ < 0, & \text{若 } \mathbf{X} \in \omega_2 \end{cases}$$

$d(\mathbf{X}) = 0$: 不可判别情况, 可随机地令 $\mathbf{X} \in \omega_1$ 或 $\mathbf{X} \in \omega_2$ 或拒绝分类。

2. 多类情况

对 M 个线性可分模式类, $\omega_1, \omega_2, \dots, \omega_M$, 有三种分类方式:

$\omega_i / \overline{\omega_i}$ 是非两分法

ω_i / ω_j 成对两分法

ω_i / ω_j 成对两分法 (无IR区)


(1) 多类情况1: $\omega_i / \bar{\omega}_i$ 是非两分法

用线性判别函数将属于 ω_i 类的模式与其余不属于 ω_i 类的模式分开。能用本方法分类的模式集称为 **整体线性可分的**。

$$d_i(\mathbf{X}) = \mathbf{W}_i^T \mathbf{X} \begin{cases} > 0, & \text{若 } \mathbf{X} \in \omega_i \\ < 0, & \text{若 } \mathbf{X} \in \bar{\omega}_i \end{cases} \quad i = 1, \dots, M$$

识别分类时:

将某个待分类模式 $\mathbf{X}$ 分别代入 M 个类的 $d(\mathbf{X})$ 中, 若只有 $d_i(\mathbf{X}) > 0$, 其他 $d_j(\mathbf{X})$ 均 < 0 , 则判为 ω_i 类。



对某一模式区, $d_i(X) > 0$ 的条件超过一个, 或全部的 $d_i(X) < 0$, 分类失效。相当于**不确定区** (indefinite region, **IR**)。

这一分法将 M 类问题转换成 M 个两类问题。在对一个样本进行分类时, 需要计算 M 个判别函数。



例 1 设有一个**二维三类**问题，其三个判别函数为：

$$d_1(X) = -x_1 + x_2 + 1 \quad d_2(X) = x_1 + x_2 - 4 \quad d_3(X) = -x_2 + 1$$

现有一模式， $\mathbf{X}=[7,5]^T$ ，试判定应属于哪类？并画出三类模式的分布区域。

解：将 $\mathbf{X}=[7,5]^T$ 代入上三式，有：

$$d_1(X) = -7 + 5 + 1 = -1 < 0$$

$$d_2(X) = 7 + 5 - 4 = 8 > 0$$

$$d_3(X) = -5 + 1 = -4 < 0$$

$$\because d_2(X) > 0, \quad d_1(X), d_3(X) < 0 \quad \therefore \mathbf{X} \in \omega_2$$


三个判别界面分别为：

$$-x_1 + x_2 + 1 = 0$$

$$x_1 + x_2 - 4 = 0$$

$$-x_2 + 1 = 0$$

图示如下：



步骤:

a) 画出界面直线。

b) 判别界面正负侧：找特殊点代入。或者：画矢量 W_0 (以原点为起点)，箭头指向的方向就是 $d(X)$ 的正侧

c) 找交集（一正测、多负则侧）。

(2) 多类情况2: ω_i/ω_j 成对两分法

一个判别界面只能分开两个类别，不需要把其余所有的类别都分开。判决函数为：

$$d_{ij}(\mathbf{X}) = \mathbf{W}_{ij}^T \mathbf{X} \quad . \quad \text{这里 } d_{ji} = -d_{ij} .$$

判别函数性质：

$$d_{ij}(\mathbf{X}) > 0, \quad \forall j \neq i; \quad i, j = 1, 2, \dots, M, \quad \text{若 } \mathbf{X} \in \omega_i$$


识别分类时：

在 M 类模式中，以 i 开始的 $M-1$ 个判决函数全为正时， $\mathbf{X} \in \omega_i$ 。其中若有一个为负，则为IR区。

能用本方法分类的模式集称为：**成对线性可分的**。

如：对一个三类问题，如果 $d_{12}(\mathbf{X}) > 0$ $d_{13}(\mathbf{X}) > 0$


则 $\mathbf{X} \in \omega_1$ 类，而 $d_{23}(\mathbf{X})$ 在判别 ω_1 类模式时不起作用。



例3 一个二维三类问题，已知三个判决函数为：

$$d_{12}(X) = -x_1 - x_2 + 5 \quad d_{13}(X) = -x_1 + 3 \quad d_{23}(X) = -x_1 + x_2$$

问模式 $X = [4, 3]^T$ 属于哪类？



解1 先计算： $d_{12}(X) = -2$,

$$d_{13}(X) = -1,$$

$$d_{23}(X) = -1$$

然后求： $d_{21}(X) = 2$,

$$d_{31}(X) = 1,$$

最后判： $d_{32}(X) = 1$

$$\left. \begin{array}{l} d_{31}(X) > 0 \\ d_{32}(X) > 0 \end{array} \right\} \Rightarrow X = [4, 3]^T \in \omega_3$$

与 $d_{12}(X)$ 值无关。

(3) 多类情况3: ω_i/ω_j 成对两分法 (无IR区)

当 ω_i/ω_j 成对两分法中的判别函数 $d_{ij}(X)$, 如果可以分解为

$$d_{ij}(X) = d_i(X) - d_j(X)$$

时, 那么 $d_i(X) > d_j(X)$ 就相当于多类情况2中的 $d_{ij}(X) > 0$ 。

此时, 对具有判别函数

$$d_i(X) = W_i^T X, \quad i = 1, \dots, M$$

的 M 类情况, 等价的判别函数性质为:


$$d_i(X) > d_j(X), \quad \forall j \neq i; \quad i, j = 1, 2, \dots, M, \quad \text{若 } X \in \omega_i$$

或:

$$d_i(X) = \max\{d_k(X), \quad k = 1, \dots, M\}, \quad \text{若 } X \in \omega_i$$

能用本方法分类的模式集称为: 线性可分的。

注意: 与前两种方法不同, 这里是以大小进行判定的, 不是仅仅以正负进行判定的。




识别分类时:

判别界面做差值。
对 ω_i 类, 应满足:
 $d_i >$ 其他所有 d_j



① 这是第二种情况的特例。因 $d_{ij}(\mathbf{X}) = d_i(\mathbf{X}) - d_j(\mathbf{X})$ ，若在第三种情况下可分（线性可分），则在第二种情况下也可分（成对线性可分），反之不一定成立。



② 除边界区外，没有不确定区域。

③ 把 M 类情况分成了 $(M-1)$ 个两类问题。并且 ω_i 类的判别界面全部与 $\omega_j (\forall j \neq i)$ 类的判别界面相邻（向无穷远处延伸的区域除外）。



例 5 一个二维三类模式分类器，满足多类情况3（成对两分法特例）要求的三个判决函数为：

$$d_1(\mathbf{X}) = -x_1 + x_2$$

$$d_2(\mathbf{X}) = x_1 + x_2 - 1$$

$$d_3(\mathbf{X}) = -x_2$$

试判断 $\mathbf{X}_0 = [1, 1]^T$ 属于哪一类，且分别给出三类的判决界面。

解：①

$$\left. \begin{array}{l} d_1(\mathbf{X}_0) = -1 + 1 = 0 \\ d_2(\mathbf{X}_0) = 1 + 1 - 1 = 1 \\ d_3(\mathbf{X}_0) = -1 \end{array} \right\} \Rightarrow \left. \begin{array}{l} d_2(\mathbf{X}_0) > d_1(\mathbf{X}_0) \\ d_2(\mathbf{X}_0) > d_3(\mathbf{X}_0) \end{array} \right\} \Rightarrow \mathbf{X}_0 \in \omega_2$$

② ω_1 类的判决函数:

$$d_1(\mathbf{X}) - d_2(\mathbf{X}) = -2x_1 + 1$$

$$d_1(\mathbf{X}) - d_3(\mathbf{X}) = -x_1 + 2x_2$$

ω_2 类的判决函数:

$$\begin{aligned} d_2(\mathbf{X}) - d_1(\mathbf{X}) \\ = 2x_1 - 1 \end{aligned}$$


$$\begin{aligned} d_2(\mathbf{X}) - d_3(\mathbf{X}) \\ = x_1 + 2x_2 - 1 \end{aligned}$$

ω_3 类的判决函数:


$$d_{31}(\mathbf{X}) = -d_{13}(\mathbf{X})$$

$$d_{32}(\mathbf{X}) = -d_{23}(\mathbf{X})$$

判决界面方程如图。



例 6 已知判决界面的位置和正负侧，按多类情况3分析三类模式的分布区域。





3. 小结

(1) 明确概念：线性可分。

一旦线性判别函数的系数 W_k 被确定以后，这些函数就可以作为模式分类器，对未知模式进行分类。

(2) $\omega_i/\bar{\omega}_i$ 与 ω_i/ω_j 两分法的比较：

对于 M 类模式的分类， $\omega_i/\bar{\omega}_i$ 是非两分法共需要 M 个判别函数， ω_i/ω_j 成对两分法需要 $M(M-1)/2$ 个。当 $M>3$ 时，后者需要更多的判别式（缺点），但对模式集进行线性可分的可能性要更大一些（优点）。

原因：

一种类别模式 ω_j 的分布要比 $M-1$ 类模式 $\bar{\omega}_i$ 的分布更为聚集，因此 ω_i/ω_j 两分法受到的限制比 $\omega_i/\bar{\omega}_i$ 少，因此线性可分可能性大。



对线性判别函数，当模式维数已知时，判别函数的形式实际上已经确定，如：三维时

$$d(\mathbf{X}) = w_1x_1 + w_2x_2 + w_3x_3 + w_4 = \mathbf{W}^T \mathbf{X}$$

$$\mathbf{X} = [x_1, x_2, x_3, 1]^T \quad \mathbf{W} = [w_1, w_2, w_3, w_4]^T$$

只要求出权向量，分类器的设计即告完成。本节介绍通过梯度算法，利用已知类别的模式样本**训练权向量** $\mathbf{W}$ 。

(一) 梯度求解算法的基本原理

1. 梯度概念

设函数 $f(\mathbf{Y})$ 是向量 $\mathbf{Y} = [y_1, y_2, \dots, y_n]^T$ 的函数, 则 $f(\mathbf{Y})$ 的梯度定义为:

$$\nabla f(\mathbf{Y}) = \frac{d}{d\mathbf{Y}} f(\mathbf{Y}) = \left[\frac{\partial f}{\partial y_1}, \frac{\partial f}{\partial y_2}, \dots, \frac{\partial f}{\partial y_n} \right]^T$$

梯度向量 最重要的性质之一:

当函数 f 的自变量沿梯度变化时, 函数的增长最快

即:

梯度的**方向**是函数 $f(\mathbf{Y})$ 在 $\mathbf{Y}$ 点增长最快的方向,

梯度的**模**是 $f(\mathbf{Y})$ 在增长最快的方向上的增长率 (增长率最大值)

显然: **负梯度指出了最陡下降方向**——梯度算法的依据。

2. 梯度算法

设两个线性可分的模式类 ω_1 和 ω_2 的样本共 N 个， ω_2 类样本乘(-1)。将两类样本分开的判决函数 $d(\mathbf{X})$ 应满足：

$$d(\mathbf{X}_i) = \mathbf{W}^T \mathbf{X}_i > 0 \quad i = 1, 2, \dots, N \quad \text{——} N \text{个不等式}$$

梯度算法的目的仍然是求一个满足上述条件的权向量，主导思想是将联立不等式求解 $\mathbf{W}$ 的问题，转换成求准则函数极小值的问题。

用负梯度向量的值对权向量 $\mathbf{W}$ 进行修正，实现使准则函数达到极小值的目的。

准则函数的选取原则：

具有唯一的最小值，并且这个最小值发生在 $\mathbf{W}^T \mathbf{X}_i > 0$ 时。

基本思路：

定义一个对错误分类敏感的准则函数 $J(W, X)$ ，在 J 的梯度方向上对权向量进行更新，从 $W(k)$ 计算 $W(k+1)$ 的递推关系为：

$$W(k+1) = W(k) + c(-\nabla J) = W(k) - c\nabla J$$

$$W(k+1) = W(k) - c \left[\frac{\partial J(W, X)}{\partial W} \right]_{W=W(k)}$$

其中 c 是固定的、正的比例因子。

梯度法求解步骤：

(1) 将样本写成规范化增广向量形式，选择准则函数，设置初始权向 $W(1)$ ，括号内为迭代次数 $k=1$ 。



(2) 依次输入训练样本 $\mathbf{X}$ 。设第 k 次迭代时输入样本为 $\mathbf{X}_i$ ，此时已有权向量 $\mathbf{W}(k)$ ，求 $\nabla J(k)$ ：

$$\nabla J(k) = \left. \frac{\partial J(\mathbf{W}, \mathbf{X}_i)}{\partial \mathbf{W}} \right|_{\mathbf{W}=\mathbf{W}(k)}$$

权向量修正为：

$$\mathbf{W}(k+1) = \mathbf{W}(k) - c \nabla J(k)$$

迭代次数 $k+1$ ，输入下一个训练样本，计算新的权向量，直至对全部训练样本完成一轮迭代。

(3) 在每一轮迭代中，如果有一个样本使 $\nabla J \neq 0$ ，回到 (2) 进行下一轮迭代。否则， $\mathbf{W}$ 不再变化，算法收敛。

例10 选择准则函数, $J(W, X) = |W^T X| - W^T X$, 简单地考虑 X 为一维增广模式的情况 $X=[0,1]$, 此时 $W=[w_1 \ w_2]$, 因为 X 的第1项为0, 简记为**标量**:

$$J(W, X) = |w| - w \quad \text{思考: } |w| - w \text{ 的导数?}$$

如果当前的 W 使得当前的 X 被错分, 即:

$$W^T X < 0 \Rightarrow w \cdot 1 < 0 \Rightarrow w < 0, \text{ 则此时有}$$

$$\nabla J = \frac{\partial J}{\partial W}(W, X) \Big|_{X=1} = \frac{\partial}{\partial w}(|w| - w) = \frac{\partial}{\partial w}(-2w) = -2$$

此时的更新方程是 $W(k+1) = W(k) - c \cdot (-2) = W(k) + 2c$

而在**正确分类**时:

$$W(k+1) = W(k) - c \nabla J$$

$$W^T X > 0 \Rightarrow w \cdot 1 > 0 \Rightarrow w > 0 \quad \nabla J = \frac{\partial}{\partial w}(|w| - w) = 0$$

$\therefore W(k+1) = W(k) - c \cdot 0 = W(k)$, 对权向量不做修正。



说明:

$$a) \quad \mathbf{W}(k+1) = \mathbf{W}(k) - c \nabla J = \mathbf{W}(k) - c \left[\frac{\partial J(\mathbf{W}, \mathbf{X})}{\partial \mathbf{W}} \right]_{\mathbf{W}=\mathbf{W}(k)}$$

随着权向量 $\mathbf{W}$ 向理想值接近, 准则函数关于 $\mathbf{W}$ 的导数越来越趋近于 0, 这意味着准则函数 J 越来越接近最小值。当最终 $\nabla J = 0$ 时, J 达到最小值, $\mathbf{W}$ 不再改变, 算法收敛。

b) c 值的选择很重要, 如 c 值太小, 收敛太慢; 但若太大, 搜索又可能过头, 甚至引起发散。一般, 开始阶段 c 取大一些, 收尾阶段取小——变步长。

c) 梯度算法是求解权向量的一般解法, 算法的具体计算形式取决于准则函数 $J(\mathbf{W}, \mathbf{X})$ 的选择, $J(\mathbf{W}, \mathbf{X})$ 的形式不同, 得到的具体算法不同。



(二) 梯度求解法的一个实现——固定增量法

准则函数: $J(W, X) = \frac{1}{2} (|W^T X| - W^T X)$

该准则函数有唯一最小值 “0”, 且发生在 $W^T X > 0$ 的时候。

求 $W(k)$ 的递推公式:

设 $X = [x_1, x_2, \dots, x_n, 1]^T$ $W = [w_1, w_2, \dots, w_n, w_{n+1}]^T$

1. 求 J 的梯度 $\nabla J = \frac{\partial J(W, X)}{\partial W} = ?$

方法: 函数对向量求导=函数对向量的分量求导, 即

$$\frac{\partial f}{\partial X} = \left[\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right]^T$$

①首先求 $\mathbf{W}^T \mathbf{X}$ 部分:

$$\frac{\partial(\mathbf{W}^T \mathbf{X})}{\partial \mathbf{W}} = \frac{\partial}{\partial \mathbf{W}} \left(\sum_{i=1}^n w_i x_i + w_{n+1} \right)$$

$$= \left[\frac{\partial}{\partial w_1} \left(\sum_{i=1}^n w_i x_i + w_{n+1} \right), \dots, \frac{\partial}{\partial w_k} \left(\sum_i w_i x_i + w_{n+1} \right), \dots, \frac{\partial}{\partial w_{n+1}} \left(\sum_i w_i x_i + w_{n+1} \right) \right]^T$$

$$= [x_1, \dots, x_k, \dots, x_n, 1]^T = \mathbf{X}$$

$$J(\mathbf{W}, \mathbf{X}) = \frac{1}{2} (\|\mathbf{W}^T \mathbf{X} - \mathbf{W}^T \mathbf{X}\|)$$

另：矩阵论中有（也可以直接按梯度定义演算）

$$\frac{d\mathbf{X}}{d\mathbf{X}^T} = \frac{d\mathbf{X}^T}{d\mathbf{X}} = \mathbf{I}_{n \times n}$$

$$\therefore \frac{\partial(\mathbf{W}^T \mathbf{X})}{\partial \mathbf{W}} = \mathbf{I}_{(n+1) \times (n+1)} \mathbf{X}_{(n+1) \times 1} = \mathbf{X}_{(n+1) \times 1}$$

② 由①的结论 $\frac{\partial(\mathbf{W}^T \mathbf{X})}{\partial \mathbf{W}} = \mathbf{X}$ 有:

$$\mathbf{W}^T \mathbf{X} > 0 \text{ 时, } \frac{\partial(|\mathbf{W}^T \mathbf{X}|)}{\partial \mathbf{W}} = \frac{\partial(\mathbf{W}^T \mathbf{X})}{\partial \mathbf{W}} = \mathbf{X}$$

$$\mathbf{W}^T \mathbf{X} \leq 0 \text{ 时, } \frac{\partial(|\mathbf{W}^T \mathbf{X}|)}{\partial \mathbf{W}} = \frac{\partial(-\mathbf{W}^T \mathbf{X})}{\partial \mathbf{W}} = -\mathbf{X}$$

$$\therefore \frac{\partial(|\mathbf{W}^T \mathbf{X}|)}{\partial \mathbf{W}} = [\text{sgn}(\mathbf{W}^T \mathbf{X})] \cdot \mathbf{X}$$

$$\text{其中 } \text{sgn}(\mathbf{W}^T \mathbf{X}) = \begin{cases} +1, & \text{若 } \mathbf{W}^T \mathbf{X} > 0 \\ -1, & \text{若 } \mathbf{W}^T \mathbf{X} \leq 0 \end{cases}$$

$$\therefore \nabla J = \frac{\partial J(\mathbf{W}, \mathbf{X})}{\partial \mathbf{W}} = \frac{1}{2} [\mathbf{X} \text{sgn}(\mathbf{W}^T \mathbf{X}) - \mathbf{X}]$$

$$J(\mathbf{W}, \mathbf{X}) = \frac{1}{2} (|\mathbf{W}^T \mathbf{X}| - \mathbf{W}^T \mathbf{X})$$

2. 求 $W(k+1)$

将 $\nabla J = \frac{\partial J(W, X)}{\partial W} = \frac{1}{2} [X \operatorname{sgn}(W^T X) - X]$ 代入

$$W(k+1) = W(k) - c \nabla J = W(k) - c \left[\frac{\partial J(W, X)}{\partial W} \right]_{W=W(k)}$$

$$\text{得: } W(k+1) = W(k) - c \frac{1}{2} [X \operatorname{sgn}(W^T(k) X) - X]$$

$$= W(k) + \frac{c}{2} [X - X \operatorname{sgn}(W^T(k) X)]$$

$$= W(k) + \begin{cases} 0, & \text{若 } W^T(k) X > 0 \\ cX, & \text{若 } W^T(k) X \leq 0 \end{cases}$$



$$\text{即: } W(k+1) = W(k) + \begin{cases} 0, & \text{若 } W^T(k)X > 0 \\ cX, & \text{若 } W^T(k)X \leq 0 \end{cases}$$

即为**固定增量算法**，与感知器算法（神经网络）完全相同。

$$W(k+1) = \begin{cases} W(k), & \text{若 } W^T(k)X_i > 0 \\ W(k) + cX_i, & \text{若 } W^T(k)X_i \leq 0 \end{cases}$$

可以看出，神经网络中的**感知器算法是梯度方法的特例**。梯度法是将感知器算法中联立不等式求解 W 的问题，转换为求目标函数极小值的问题，将原来有多个解的情况，变成求最优解的情况。

分类算法是通过模式样本来确定判别函数的系数，因此必须采用有代表性的数据，这样训练出来的判别函数，能合理反映模式数据的区隔情况。



线性回归：基于线性模型的回归，相应的线性模型称为线性回归模型。一般而言，解释变量和响应变量都是连续值。

对于任意给定的样本 $\mathbf{x}$ ，线性回归模型表示为：

$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \cdots + w_mx_m$$

其中 $\mathbf{w} = (w_1, w_2, \dots, w_m)^T$ 为参数向量。

线性回归与线性分类问题非常相似，只不过线性回归的响应变量一般是定量型，而线性分类涉及的响应变量主要是定性型，比如：有病 vs 无病。穷人 vs 富人。喜欢看武打片 vs 喜欢看言情片。为了适合计算，把这些定性变量用 $\{0, 1\}$ 或 $\{-1, +1\}$ 代替。


使用符号函数作为判决函数：简单观察可知，前面讨论线性判别分类时，实际上是在线性回归函数 $f(\mathbf{x})$ （也即 $d(\mathbf{X})$ ）上，复合了一个符号型判决函数：

$$y = \text{sign}(f(\mathbf{x})) = \text{sign}(w_1 x_1 + w_2 x_2 + \cdots + w_m x_m)$$

这个判决函数非常硬——只看是否大于零，不管与零有多远！

我们如何利用成熟的线性回归方法进行更细致的分类呢？

我们能不能更多地利用判决函数值的大小信息、而不仅仅是利用其正负信息呢？




使用跃阶函数作为判决函数：当类标记从 $\{1, -1\}$ 改为 $\{1, 0\}$ 时，相当于把判决函数改为阶跃函数（step function）

$$\text{step}(x) = \frac{1}{2}(\text{sign}(x) + 1)$$

当 $f(x)$ 大于零时将样本 x 划分为正类；小于零时将 x 划分为负类；等于零时将 x 随机划分。

$$\text{step}(f(x)) = \begin{cases} 0 & f(x) < 0; \\ 0.5 & f(x) = 0; \\ 1 & f(x) > 0; \end{cases}$$






使用Sigmoid作为分类判决函数：具有良好数学性质的判别函数，克服了跃阶函数的不连续性，实现对连续值的离散化

$$g(f(x)) = \text{Sigmoid}(f(x)) = \frac{1}{1+e^{-w^T x}}$$

令 $H(x) = \text{Sigmoid}(f(x))$ ， $H(x)$ 值域为 $(0, 1)$ ，可将 $H(x)$ 看成是一个关于 x 的概率分布，即：

- 若 $H(x)$ 的值越接近1，则 x 属于正类的可能性就越大
- 若 $H(x)$ 的值越接近0，则 x 属于正类的可能性就越小




1 对数几率回归的模型

- 给定数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ ，样本空间由 d 维向量张成， $x_i = (x_{i1}, x_{i2}, \dots, x_{id})^T$ ， $y_i \in \{c_1 = 1, c_0 = 0\}$
- 找一个单调可微的联系函数，将样本 x_i 的线性回归预测值 z_i 与样本的分类后验概率 $\hat{y}_i = P(c_1 | x_i)$ 联系起来，构成一个线性分类器：即对样本 x_i 与其分类后验概率 $\hat{y}_i = P(c_1 | x_i)$ 做广义线性回归，选择 Logistic 函数作为联系函数

- Logistic 函数是一种形为 S（Sigmoid）的函数，由皮埃尔·弗朗索瓦·韦吕勒（Pierre-François Verhulst）在研究人口增长时提出：

$$f(x) = \frac{1}{1 + e^{-x}}$$



- LR模型的设计思想：

$$\mathbf{x}_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{id} \end{bmatrix} \xrightarrow{\text{①线性回归}} z_i = \mathbf{x}_i^T \mathbf{w} + w_0 \xrightarrow{\text{②Logistic映射}} \hat{y}_i = \frac{1}{1+e^{-z_i}} = \frac{1}{1+e^{-(\mathbf{x}_i^T \mathbf{w} + w_0)}} = P(c_1 | X = \mathbf{x}_i)$$

$$\text{满足: } \begin{cases} z_i > 0 & \hat{y}_i = P(c_1 | \mathbf{x}_i) > 0.5 \\ z_i = 0 & \hat{y}_i = P(c_1 | \mathbf{x}_i) = 0.5 \\ z_i < 0 & \hat{y}_i = P(c_1 | \mathbf{x}_i) < 0.5 \end{cases}$$

如样本 $\mathbf{x}_i$ 属于正例，则 $z_i > 0$ ； $\mathbf{x}_i$ 属于负例
则 $z_i < 0$ ，样本在决策界上，则 $z_i = 0$



- 在贝叶斯分类器中, $P(c_1|\mathbf{x})=P(c_0|\mathbf{x})$ 是二分类的分类决策界, 则:

- 决策界满足:

$$\ln \frac{P(c_1|\mathbf{x})}{P(c_0|\mathbf{x})} = \ln \frac{\hat{y}}{1-\hat{y}} = 0$$

$$\text{则: } \ln \frac{\hat{y}}{1-\hat{y}} = \ln \frac{1}{\frac{e^{-z}}{1+e^{-z}}} = \ln e^z = z = 0 \quad \text{即 } z = \mathbf{x}^T \mathbf{w} + w_0 = 0 \quad \text{是决策界方程}$$

- 同时 $z = \ln \frac{\hat{y}}{1-\hat{y}}$ 是 $\mathbf{x}$ 作为正例与反例的概率的比值的对数, 这个比值又被称为“几率”, 这也就是模型被称为“对数几率回归”的由来

2 对数几率回归的学习准则

➤ LR模型的学习准则可以从最大似然估计导出，用于衡量模型预测值与真实值之间的差异

- 考虑让样本 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\} \in \{0, 1\}$ 中每个样本 $(\mathbf{x}_i, y_i)$ 属于其真实标记的概率越大越好，构造似然函数：

$$l(\mathbf{w}) = \prod_{i=1}^m [P(\mathbf{x}_i)]^{y_i} [1 - P(\mathbf{x}_i)]^{1-y_i} \quad \leftarrow \text{伯努利型的似然估计}$$

$$\text{其中 } P(\mathbf{x}) = P(c_1|\mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{x}^T \mathbf{w} + w_0)}} = \frac{e^{(\mathbf{x}^T \mathbf{w} + w_0)}}{1 + e^{(\mathbf{x}^T \mathbf{w} + w_0)}}$$

- 则其对数似然函数有：

$$ll(\mathbf{w}) = \ln l(\mathbf{w}) = \sum_{i=1}^m y_i \cdot \ln P(\mathbf{x}_i) + (1 - y_i) \cdot \ln(1 - P(\mathbf{x}_i))$$



- LR模型的优化目标函数可以写为：

$$\mathbf{w}^* = \operatorname{argmax}_{\mathbf{w}} ll(\mathbf{w}) = \operatorname{argmax}_{\mathbf{w}} \left[\sum_{i=1}^m y_i \cdot \ln P(\mathbf{x}_i) + (1 - y_i) \cdot \ln(1 - P(\mathbf{x}_i)) \right]$$

- 对上式取负号，可以得到等价的优化目标函数：

$$\begin{aligned} L(\mathbf{w}) &= -ll(\mathbf{w}) = \sum_{i=1}^m -y_i \cdot \ln P(\mathbf{x}_i) - (1 - y_i) \cdot \ln(1 - P(\mathbf{x}_i)) \\ \mathbf{w}^* &= \operatorname{argmin}_{\mathbf{w}} L(\mathbf{w}) \\ &= \operatorname{argmin}_{\mathbf{w}} \left[\sum_{i=1}^m -y_i \cdot \ln P(\mathbf{x}_i) - (1 - y_i) \cdot \ln(1 - P(\mathbf{x}_i)) \right] \end{aligned}$$

- 其中 $L(\mathbf{w})$ 函数即LR模型的代价（损失）函数，又叫“**二分类交叉熵（cross-entropy）**”损失函数


3 交叉熵损失

- 用交叉熵（互熵）定义损失函数经常用于分类问题中，在对数几率回归以及分类神经网络中会大量使用到

→第1讲



- 克劳德·艾尔伍德·香农（Claude Elwood Shannon, 1916—2001），出生于美国密歇根州佩托斯基，美国数学家、发明家、密码学家，信息论创始人，美国国家工程院院士、美国国家科学院院士、美国艺术与科学院院士，麻省理工学院名誉教授。香农提出了信息熵的概念，为信息论和数字通信奠定了基础



克劳德·艾尔伍德·香农

Claude Elwood Shannon

(1916.4—2001.2)



- 根据香农信息论，设随机事件 X 有 k 个可能取值（对应 k 分类），其中 $X = x_k$ 的信息量：

$$I(x_k) = -\log P(X = x_k)$$

- 信息熵（entropy）是信息量函数的期望。信息熵越大表明信息越不确定（越丰富），信息熵越小表明信息越确定（越枯燥）

$$\text{Ent}(X) = -\sum_{i=1}^k P(X = x_i) \log P(X = x_i)$$

- 随机事件 X 有 k 个可能取值，其真实分布 $P(X)$ 与近似分布 $Q(X)$ 的关系可以用交叉熵来刻画：

$$\text{Ent}(P, Q) = -\sum_{i=1}^k P(X = x_i) \log Q(X = x_i)$$

从信息编码角度看， $H(X)$ 表示随机变量 X 的最短编码的平均长度，因为二进制所以 $\log_2$



➤ 对于样本 $\mathbf{x}_i$, 其标记值为 y_i , 预测值为 $\hat{y}_i$, 其二分类交叉熵:

- 其二分类交叉熵:

$$\begin{aligned} & -y_i \cdot \ln P(\mathbf{x}_i) - (1 - y_i) \cdot \ln(1 - P(\mathbf{x}_i)) \\ & = -y_i \cdot \ln \hat{y}_i - (1 - y_i) \cdot \ln(1 - \hat{y}_i) \end{aligned} \quad \text{二分类, 写为2项和}$$

- 对于 m 个样本, 其代价函数:

$$\begin{aligned} L(\mathbf{w}) &= - \sum_{i=1}^m [y_i \cdot \ln P(\mathbf{x}_i) + (1 - y_i) \cdot \ln(1 - P(\mathbf{x}_i))] \\ &= - \sum_{i=1}^m \left[y_i \cdot \ln \frac{P(\mathbf{x}_i)}{1 - P(\mathbf{x}_i)} + \ln(1 - P(\mathbf{x}_i)) \right] \\ &= - \sum_{i=1}^m [y_i \cdot (\mathbf{x}^T \mathbf{w} + w_0) - \ln(1 - P(\mathbf{x}_i))] \end{aligned}$$



- 交叉熵损失的正则化与线性回归中MSE正则化类似

$$\text{代价函数 } L(\mathbf{w}) = - \sum_{i=1}^m \left[y_i \cdot (\mathbf{x}^T \mathbf{w} + w_0) - \ln(1 + e^{\mathbf{x}^T \mathbf{w} + w_0}) + \frac{\lambda}{2} \sum_{j=1}^d w_j^2 \right]$$

w 的L2范数的平方

λ 为正则化系数



e.g. 假设一组训练样本的标记值为{1, 0, 1, 0, 1}, 分类器A的预测结果为{0.9, 0.01, 0.95, 0.03, 0.99}, 分类器B的预测结果为{0.85, 0.45, 0.75, 0.55, 0.7}, 两个分类器分别计算**平均交叉熵**:

A:
$$-[(1\ln 0.9 + 0\ln 0.1) + (0\ln 0.01 + 1\ln 0.99) + (1\ln 0.95 + 0\ln 0.05) + (0\ln 0.03 + 1\ln 0.97) + (1\ln 0.99 + 0\ln 0.01)] \times 0.2 = 0.207 \times 0.2 = 0.04$$

B:
$$-[(1\ln 0.85 + 0\ln 0.15) + (0\ln 0.45 + 1\ln 0.55) + (1\ln 0.75 + 0\ln 0.25) + (0\ln 0.55 + 1\ln 0.45) + (1\ln 0.7 + 0\ln 0.3)] \times 0.2 = 2.203 \times 0.2 = 0.44$$

上述两种情况对比, A的损失明显低于B的损失, 说明分类器A更优

注: 按照信息熵的定义, log应该取2为底。但机器学习中一般需要对交叉熵损失求导, 故log用ln代替



4 对数几率回归的优化算法

➤ 求解最小交叉熵损失函数

- 梯度下降法 (Gradient descent method) (同前)
- 牛顿迭代法 (Newton method) *



现在讨论如何根据训练数据, 对逻辑回归模型进行求解。

问题: 希望用数据点 $(\mathbf{x}, y)$ 的对数胜率 $\text{logit}(p(y|\mathbf{x}))$ 进行线性回归建模

$$\text{logit}(p(y = 1|\mathbf{x})) = \mathbf{w}^T \mathbf{x} \equiv \mathbf{w} \cdot \mathbf{x}$$

由前分析, 训练数据点 $(\mathbf{x}, y)$ 在该模型 $\mathbf{w}$ 下属于正类的概率值为

$$p(y = 1|\mathbf{x}) = \text{logistic}(\mathbf{w} \cdot \mathbf{x}) = \frac{1}{1 + \exp(-\mathbf{w} \cdot \mathbf{x})} \equiv h(\mathbf{w}; \mathbf{x}) \equiv h(\mathbf{x})$$

而属于负类的概率值为 $(1 - h(\mathbf{x}))$ 。由于 y 取值于 $\{0, 1\}$, $y|\mathbf{x}$ 的概率分布 (也即该数据点关于参数 $\mathbf{w}$ 似然值) 可以写为一个精致的表达式

$$p(y|\mathbf{x}) = p(y = 1|\mathbf{x})^y [1 - p(y = 1|\mathbf{x})]^{1-y}$$

简记: $\pi(\mathbf{x}) \equiv p(y = 1|\mathbf{x})$ 。因此, $(\mathbf{x}, y)$ 的似然函数为:

$$\pi(\mathbf{x})^y [1 - \pi(\mathbf{x})]^{1-y}$$



根据模型拟合的**最大似然原则**，如果观察到 **N** 个训练数据点 $\{(x_i, y_i)\}_{i=1}^N$ ，则这 **N** 个数据点关于模型 **w** 的联合似然函数为：

$$\prod_{i=1}^N [\pi(x_i)]^{y_i} [1 - \pi(x_i)]^{1-y_i}$$

这就转化为典型的最大似然参数估计问题。使用梯度法或拟牛顿法，对下面的对数似然函数进行求解即可：

$$\begin{aligned} L(w) &= \sum_{i=1}^N [y_i \log \pi(x_i) + (1 - y_i) \log(1 - \pi(x_i))] \\ &= \sum_{i=1}^N \left[y_i \log \frac{\pi(x_i)}{1 - \pi(x_i)} + \log(1 - \pi(x_i)) \right] \\ &= \sum_{i=1}^N [y_i (w \cdot x_i) - \log(1 + \exp(w \cdot x_i))] \end{aligned}$$



- 机器学习中的经典问题：在对数几率回归中为什么选用交叉熵作为损失函数，而不选用MSE作为损失函数？

- 考虑单样本的平方误差函数和交叉熵函数，联系（激活）函数都用logistic函数，不妨考虑样本 x 只有一维特征：

$$L_1(w) = (y_i - \hat{y}_i)^2$$

$$L_2(w) = -y_i \cdot \ln \hat{y}_i - (1 - y_i) \cdot \ln(1 - \hat{y}_i)$$

$$\hat{y}_i = \frac{1}{1 + e^{-(wx_i + w_0)}} = f(w)$$

Logistic函数满足: $f'(w) = \hat{y}_i(1 - \hat{y}_i)x_i$



$$\begin{aligned}
 L'_1(w) &= \frac{\partial L_1(w)}{\partial w} = \frac{\partial L_1(w)}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial w} = -2(y_i - \hat{y}_i)\hat{y}_i(1 - \hat{y}_i)x_i \\
 &= -2(y_i\hat{y}_i - y_i\hat{y}_i^2 - \hat{y}_i^2 + \hat{y}_i^3)x_i \\
 L''_1(w) &= \frac{\partial L'_1(w)}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial w} = -2(y_i\hat{y}_i - y_i\hat{y}_i^2 - \hat{y}_i^2 + \hat{y}_i^3)x_i\hat{y}_i(1 - \hat{y}_i)x_i \\
 &= -2[3\hat{y}_i^2 - 2\hat{y}_i(y_i + 1) + y_i]x_i^2\hat{y}_i(1 - \hat{y}_i)
 \end{aligned}$$

注意到, $y_i \in \{0,1\}$, $\hat{y}_i \in [0,1]$, 所以 $\hat{y}_i(1 - \hat{y}_i) \in (0, \frac{1}{4})$, $x_i^2 \geq 0$

令 $\varphi(\hat{y}_i) = -2[3\hat{y}_i^2 - 2\hat{y}_i(y_i + 1) + y_i]$, 则:

- 当 $y_i = 0$ 时, $\varphi(\hat{y}_i) = -2[3\hat{y}_i^2 - 2\hat{y}_i]$

$$\hat{y}_i \in [0, \frac{2}{3}] \text{ 时 } \varphi(\hat{y}_i) \geq 0, \quad \hat{y}_i \in (\frac{2}{3}, 1] \text{ 时 } \varphi(\hat{y}_i) < 0$$

- 当 $y_i = 1$ 时, $\varphi(\hat{y}_i) = -2[3\hat{y}_i^2 - 4\hat{y}_i + 1] = -2[3(\hat{y}_i - \frac{1}{3})(\hat{y}_i - 1)]$

$$\hat{y}_i \in [\frac{1}{3}, 1] \text{ 时 } \varphi(\hat{y}_i) \geq 0, \quad \hat{y}_i \in [0, \frac{1}{3}) \text{ 时 } \varphi(\hat{y}_i) < 0$$

即 $L''_1(w)$ 不能恒 ≥ 0 , $L_1(w)$ 不是凸函数



- 同理，前面已经推导：

$$L_2(w) = -y_i \cdot (wx_i + w_0) + \ln(1 + e^{wx_i + w_0})$$

则：


$$L'_2(w) = \frac{\partial L_2(w)}{\partial w} = \frac{x_i}{1 + e^{-(wx_i + w_0)}} - x_i y_i$$

$$L''_2(w) = \frac{x_i^2 e^{-(wx_i + w_0)}}{(1 + e^{-(wx_i + w_0)})^2} \quad \text{恒} \geq 0, \text{ 所以 } L_2(w) \text{ 是凸函数}$$

- 由于使用logistic非线性激活函数，MSE损失函数是非凸的不容易找到全局最优解，故不选用。在对数几率回归中交叉熵损失函数是凸函数，进而可以使用梯度下降法进行求解

7 模型小结

模型



- 核心参数：
特征权向量 $\mathbf{w}$

策略 (准则)

- 最小交叉熵损失：

$$\operatorname{argmin}_{\mathbf{w}} \left[\sum_{i=1}^m -y_i \cdot \ln P(\mathbf{x}_i) - (1 - y_i) \cdot \ln(1 - P(\mathbf{x}_i)) \right]$$

算法

- 梯度下降法：
$$\mathbf{w}^{(i+1)} \leftarrow \mathbf{w}^{(i)} - \eta \cdot \frac{\partial L(\mathbf{w})}{\partial \mathbf{w}}$$



- 罗纳德·费希尔（1890~1962），英国统计与遗传学家，现代统计科学的奠基人之一，并对达尔文进化论作了基础澄清的工作。线性判别分析（Linear Discriminant Analysis, LDA）是一种经典的线性模型，在两分类问题上最早由费希尔在1936年提出，也被称为Fisher判别分析



罗纳德·费希尔
Ronald Fisher
(1890—1962)

- 线性判别分析（Linear Discriminant Analysis, LDA）模型是一种线性分类器模型。同时该模型也是一种有监督的降维模型



注意区分：在机器学习领域还有另外一个LDA，被称为隐迪利克雷分配（Latent Dirichlet Allocation），主要用于文档主题分析，现在也被广泛用于时空数据分析。它和线性判别分析都是机器学习的经典模型，应用领域完全不同

1 线性判别分析的模型

- LDA的思想：对于二分类问题，在给定的训练样集上，设法将样例投影到一条“直线”上：使得同类样例的投影点尽可能的近，异类样例的投影点尽可能的远离


注意：这不是直线方程！

- 作为特征提取模型：

将 d 维度数据投影到 $k-1$ 维上， k 为样本的类别数

- 作为分类器：

根据样本训练好这条“直线”，在预测阶段将新样本投影到该直线上，根据投影点的位置确定新样本的类别






e.g. 计算向量 $(3, 2)$ 在直线 $3t_1 - t_2 = 0$ 下的投影

解：由直线方程可知直线的方向向量 $\mathbf{w} = (1, 3)^T$ ，化为单位向量 $\mathbf{w}^T = (\sqrt{10}/10, 3\sqrt{10}/10)$ ，则其在直线下的投影为

$$\begin{pmatrix} \sqrt{10}/10 \\ 3\sqrt{10}/10 \end{pmatrix} \cdot \begin{pmatrix} 3 \\ 2 \end{pmatrix} = (\sqrt{10}/10, 3\sqrt{10}/10) \begin{pmatrix} 3 \\ 2 \end{pmatrix} = (9\sqrt{10}/10)$$

点乘



*注意： $9\sqrt{10}/10$ 是 t_1-t_2 坐标系下向量 $(3, 2)$ 在新空间 $\mathbf{w}$ 下的投影坐标。因新空间（直线）只有一个基向量，所以投影点为一个数（2维投影到1维）。这个数字其实也是 t_1-t_2 坐标系下投影向量 $(9/10, 27/10)$ 的长度

Tips

- 平面直线 $At_1 + Bt_2 + C = 0$ 的法向量为 (A, B) ，方向向量为 $(-B, A)$
- 在同一坐标系下，向量 $\vec{u}$ 在单位向量 $\vec{v}$ 的投影向量为 $(\vec{u} \cdot \vec{v}) \times \vec{v}$

➤ 考虑二分类, 样本 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots (\mathbf{x}_m, y_m)\}$, $y_i \in \{0, 1\}$, 每个样本含有 d 维特征, $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{id})^T$

- 第 i 类样本的集合: X_i
- 第 i 类样本的均值向量: μ_i
- 第 i 类样本的散度矩阵: Σ_i
- 两类样本的中心向量在直线 $\mathbf{w}$ 上的投影: $\mathbf{w}^T \mu_0$ 和 $\mathbf{w}^T \mu_1$ (直线 $\mathbf{w}$ 下的1维坐标)
- 两类样本在直线 $\mathbf{w}$ 上投影点的方差: $\mathbf{w}^T \Sigma_0 \mathbf{w}$ 和 $\mathbf{w}^T \Sigma_1 \mathbf{w}$

散度矩阵和协方差矩阵很像, 少乘一个均值系数

$\mathbf{w}$ 为直线的方向向量



再次强调! m 是样本个数, d 是样本维数



2 线性判别分析的学习准则

➤ 考虑优化目标:

- 同类样例的投影点尽可能的近: 两个投影的协方差和尽可能小

$$\mathbf{w}^T \Sigma_0 \mathbf{w} + \mathbf{w}^T \Sigma_1 \mathbf{w}$$

- 异类样例投影点尽可能的远离: 各均值向量投影点距离尽可能大

$$\|\mathbf{w}^T \mu_0 - \mathbf{w}^T \mu_1\|_2^2$$

距离度量选用2范数平方

➤ 构造目标函数:

$$J = \frac{\|\mathbf{w}^T \mu_0 - \mathbf{w}^T \mu_1\|_2^2}{\mathbf{w}^T \Sigma_0 \mathbf{w} + \mathbf{w}^T \Sigma_1 \mathbf{w}} = \frac{\mathbf{w}^T (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T \mathbf{w}}{\mathbf{w}^T (\Sigma_0 + \Sigma_1) \mathbf{w}}$$

推导:

$$J = \frac{\|\mathbf{w}^T \boldsymbol{\mu}_0 - \mathbf{w}^T \boldsymbol{\mu}_1\|_2^2}{\mathbf{w}^T \boldsymbol{\Sigma}_0 \mathbf{w} + \mathbf{w}^T \boldsymbol{\Sigma}_1 \mathbf{w}} = \frac{\|(\mathbf{w}^T \boldsymbol{\mu}_0 - \mathbf{w}^T \boldsymbol{\mu}_1)^T\|_2^2}{\mathbf{w}^T (\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1) \mathbf{w}}$$
$$= \frac{\|(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}\|_2^2}{\mathbf{w}^T (\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1) \mathbf{w}} = \frac{[(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}]^T (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}}{\mathbf{w}^T (\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1) \mathbf{w}}$$
$$= \frac{\mathbf{w}^T (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1) (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}}{\mathbf{w}^T (\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1) \mathbf{w}}$$

类内散度矩阵 S_w

类间散度矩阵 S_b



- 矩阵转置的性质: $(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T$



- 定义类内散度 (within-class scatter) 矩阵 S_w :

$$S_w = \Sigma_0 + \Sigma_1 = \sum_{x \in X_0} (x - \mu_0)(x - \mu_0)^T + \sum_{x \in X_1} (x - \mu_1)(x - \mu_1)^T$$

参考
协方差定义

- 定义类间散度 (between-class scatter) 矩阵 S_b :

$$S_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T$$

- 目标函数可以重写为一种称作广义瑞利商 (generalized Rayleigh quotient) 的形式:

$$J = \frac{w^T (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w} = \frac{w^T S_b w}{w^T S_w w}$$

3 线性判别分析的优化算法

- 广义瑞利商分子分母都是关于 $\mathbf{w}$ 的二次项，因此最优参数 $\mathbf{w}^*$ 的长度不重要，只要确定其方向，因此令 $\mathbf{w}^T S_w \mathbf{w} = 1$ ，优化目标等价为：

$$\begin{aligned} \mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} \quad & (-\mathbf{w}^T S_b \mathbf{w}) \\ \text{s.t.} \quad & \mathbf{w}^T S_w \mathbf{w} = 1 \end{aligned}$$

- 构造Lagrange函数：

$$L(\mathbf{w}, \lambda) = \mathbf{w}^T S_b \mathbf{w} - \lambda(\mathbf{w}^T S_w \mathbf{w} - 1)$$

$$\frac{\partial L}{\partial \mathbf{w}} = S_b \mathbf{w} - \lambda S_w \mathbf{w} = 0$$

$$\text{极值解 } \mathbf{w}^* \text{ 应满足 } \Rightarrow S_w^{-1} S_b \mathbf{w}^* = \lambda \mathbf{w}^*$$

求解有约束的极值：

Lagrange乘数法



$S_w^{-1} S_b$ 矩阵的秩?

求目标函数极值问题变成了求矩阵特征值问题，最优投影方向就是这个 $S_w^{-1} S_b$ 矩阵的特征向量

- 可知 $\mathbf{w}^*$ 是 $S_w^{-1} S_b$ 的特征向量

$$\lambda \mathbf{w}^* = S_w^{-1} (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1) (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}^*$$

因为 $(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}^*$ 是标量, 不影响 $\mathbf{w}^*$ 的方向, 可以省去特征值分解的过程

即 $\mathbf{w}^*$ 与 $S_w^{-1} (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)$ 共线:

$$\mathbf{w}^* = S_w^{-1} (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)$$

➤ 最优投影直线的方向向量: $\mathbf{w}^* = S_w^{-1} (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1) = (\Sigma_0 + \Sigma_1)^{-1} (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)$

是一个与样本均值和类内方差有关量




[扩展阅读: LDA为什么长这样?](#)

探讨: LDA分类器是属于判别式方法, 还是生成式方法?

4 用LDA处理二分类问题

- 对 k, l 二分类问题：在投影直线确定后所有样本将会映射到一维空间中。过两类样本中心向量投影点的中点，垂直于投影直线的垂线就是分类决策界



决策界的法向量是什么

决策边界

- 投影直线 $w = (\Sigma_l + \Sigma_k)^{-1}(\mu_k - \mu_l)$
 - 若两类样本协方差相同: $w = \frac{1}{2} \Sigma^{-1} (\mu_k - \mu_l)$
 - 投影连线的中点:
- $$\frac{1}{2} (\mu_k + \mu_l)^T w = \frac{1}{4} (\mu_k + \mu_l)^T \Sigma^{-1} (\mu_k - \mu_l)$$
- 线性判别分析的决策界:

$$g(x) = \frac{1}{2} x^T \Sigma^{-1} (\mu_k - \mu_l) - \frac{1}{4} (\mu_k + \mu_l)^T \Sigma^{-1} (\mu_k - \mu_l) = 0$$

5 用LDA处理降维问题*

- LDA也常被视为一种经典的**监督降维**技术，应对样本的“维度爆炸”，经常被用在更为复杂的ML模型的预处理阶段。二分类LDA是将样本投影到一根直线上， k 类LDA至多投影到 $k-1$ 维上
- 定义全局散度（global scatter）矩阵 S_t :

$$S_t = \sum_{x \in D} (x - \bar{\mu})(x - \bar{\mu})^T$$

$\bar{\mu}$:全体样本的均值

- 定义类内散度（within-class scatter）矩阵 S_w :


$$S_w = \sum_{i=1}^k \sum_{x \in X_i} (x - \mu_i)(x - \mu_i)^T$$

k 个类的类内散度之和

➤ 定义类间散度 (between-class scatter) 矩阵 S_b :

$$S_B = S_t - S_w = \sum_{i=1}^k |X_i| (\mu_i - \bar{\mu})(\mu_i - \bar{\mu})^T \quad |X_i|: \text{第} i \text{类样本数}$$

LDA有监督降维



输入：数据集 $D = \{x^{(1)}, x^{(1)}, \dots, x^{(m)}\}$

输出：降维后的样本集 D' ;

- 计算类内散度矩阵 S_w 和类间散度矩阵 S_B ;
- 计算矩阵 $S_w^{-1} S_B$ 的特征值;
- 找出矩阵 $S_w^{-1} S_B$ 最大的 $k-1$ 个特征值和其对应的 $k-1$ 个特征向量 $(w_1, w_2, \dots, w_{k-1})$;
- 将原始样本集投影到以 $(w_1, w_2, \dots, w_{k-1})$ 为基向量生成的低维空间中($k-1$ 维), 得到新样本集 D'

→ 第七讲



- 回顾LDA求解过程的这个步骤： $\Rightarrow S_W^{-1}S_B\mathbf{w}^* = \lambda\mathbf{w}^*$

这里 $\mathbf{w}^*$ 是 $S_W^{-1}S_B$ 的特征向量。因为两个矩阵乘积的不能超过各自的秩，所以

$$\text{rank}(S_W^{-1}S_B) \leq \min\{r(S_W^{-1}), r(S_B)\}$$

- 而类间散度矩阵 $\text{rank}(S_B) = \text{rank}\left(\sum_{i=1}^k |X_i|(\boldsymbol{\mu}_i - \bar{\boldsymbol{\mu}})(\boldsymbol{\mu}_i - \bar{\boldsymbol{\mu}})^T\right)$

$$\begin{aligned} &\leq \sum_{i=1}^k \text{rank}(|X_i|(\boldsymbol{\mu}_i - \bar{\boldsymbol{\mu}})(\boldsymbol{\mu}_i - \bar{\boldsymbol{\mu}})^T) \\ &= \sum_{i=1}^k \text{rank}(\boldsymbol{\mu}_i - \bar{\boldsymbol{\mu}}) = k \quad (\text{rank}(\boldsymbol{\mu}_i - \bar{\boldsymbol{\mu}}) = 1) \end{aligned}$$

矩阵和的秩不大于矩阵秩的和



- 矩阵的秩： $\text{rank}(A+B) \leq \text{rank}(A) + \text{rank}(B)$
 $\text{rank}(AB) \leq \min\{\text{rank}(A), \text{rank}(B)\}$



μ_i 是每个类 X_i 的均值向量，如果求出前 $k-1$ 个 μ_i ，最后一个 μ_k 可以由前 $k-1$ 个 μ_i 线性表出，因此 S_B 最多有 $k-1$ 个特征向量，秩最大为 $k-1$

$$\text{rank}(S_W^{-1}S_B) \leq k - 1$$

- 所以二分类LDA是将样本投影到一根直线上， k 分类LDA至多投影到 $k-1$ 维上。作为降维工具，LDA降维是一种有监督降维（需要知道类标记），且将 d 维样本最多降至 $k-1$ 维




1 用多次二分类实现多分类

- 现实中我们常遇到多分类学习任务。通常采用将一个多分类任务拆分为若干个二分类任务，将二分类学习推广到多分类学习。在测试时，对这些分类器的预测结果进行集成以获得最终结果

经典拆分策略

- 一对一, One vs.One, OvO
- 一对其余, One vs.Rest, OvR
- 多对多, Many vs. Many, MvM *

- OvO将 N 个类两两配对，构造 $k(k-1)/2$ 个分类器，把它们预测最多的类别作为最终的分类结果（投票）
- OvR则是每次将一个类作为正例、其他类的样例作为反例来训练 N 个分类器。在测试时若仅有一个分类器预测为正类，则对应的类别标记作为最终分类结果






2 引入Softmax函数

- 对数几率回归使用的Logistic函数是一个典型的Sigmoid函数（S型函数），能够将样本的线性回归预测值映射到(0,1)之间，代表其属于正类的概率，因此适用于二分类问题
- 对于 k 分类系统，引入名为“**软最大 Softmax 函数**”，考虑样本集 $\{(\mathbf{x}_1, \mathbf{y}_1), (\mathbf{x}_2, \mathbf{y}_2), \dots, (\mathbf{x}_m, \mathbf{y}_m)\}$ ，标记 $\mathbf{y}_i$ 是形如 $(0, 0, 0, 1, 0, 0, \dots, 0)^T$ 的 $k \times 1$ 向量。输出 $\hat{\mathbf{y}}_i$ 为 $(\hat{c}_1, \hat{c}_2, \hat{c}_3, \dots, \hat{c}_k)^T$ 的 $k \times 1$ 向量，其中 $\hat{c}_j$ 为样本 $\mathbf{x}_i$ 属于 c_j 类的概率，满足：

$$\hat{c}_j = P(c_j | \mathbf{x}_i) = \frac{e^{(\mathbf{x}_i^T \mathbf{w}_j)}}{\sum_{l=1}^k e^{(\mathbf{x}_i^T \mathbf{w}_l)}}$$

其中 $\mathbf{w}_l$ 是第 l 类（第 l 个广义线性回归）使用的参数向量 $[w_{l1}, w_{l1}, \dots, w_{ld}, w_{l0}]$


增广偏置参数




Softmax函数的计算流程

➤ Sigmoid函数与Softmax函数对比

Logistic



Softmax





c.g. 在手写数字识别任务中，如果样本是数字“5”，那么真实分布应该为：[0, 0, 0, 0, 0, 1, 0, 0, 0, 0]，如果输出的分布为：[0.1, 0.1, 0, 0, 0, 0.7, 0, 0.1, 0, 0]，则k=10，该样本的10分类交叉熵损失为：

10分类，写为10项和

$$Loss = -0 \times \log 0.1 - 0 \times \log 0.1 - 0 \times \log 0 - 0 \times \log 0 - 0 \times \log 0 - 1 \times \log 0.7 - 0 \times \log 0 - 0 \times \log 0.1 - 0 \times \log 0 - 0 \times \log 0 \approx 0.3567$$

0log0=0

如果输出的分布为：[0.2, 0.3, 0.1, 0, 0, 0.3, 0.1, 0, 0, 0]，那么损失函数得：

$$Loss = -0 \times \log 0.2 - 0 \times \log 0.3 - 0 \times \log 0.1 - 0 \times \log 0 - 0 \times \log 0 - 1 \times \log 0.3 - 0 \times \log 0.1 - 0 \times \log 0 - 0 \times \log 0 - 0 \times \log 0 \approx 1.2040$$

上述两种情况对比，第一个分布的损失明显低于第二个分布的损失，说明第一个分布更接近于真实分布

注：同样使用ln计算

- 线性关系简单、易于理解和计算，而非线性关系更为复杂和多样化
- 线性思维是一种直线的、单向的、缺乏变化的思维方式。它倾向于将事物简化为一连串的因果关系，按照时间顺序或逻辑顺序逐步推导。非线性思维不拘泥于因果关系、分类和区分，注重整体性、相对性、动态性、创造性和和谐性


- [1]. 统计学-线性回归中的假设检验[EB/OL][2018-01-08]. <https://zhuanlan.zhihu.com/p/32750128>
- [2]. Jackeeeee M.一文读懂信息熵、交叉熵和相对熵（KL散度）[EB/OL][2022-12-21]. <https://zhuanlan.zhihu.com/p/593362066>
- [3]. DeAlVe.教科书上的LDA为什么长这样？ [EB/OL][2018-08-30]. https://www.sohu.com/a/250923766_500659
- [4]. July.支持向量机通俗导论（理解SVM的三层境界） [EB/OL][2016-11-01]. https://blog.csdn.net/v_july_v/article/details/7624837

本章小结




武汉大学
WUHAN UNIVERSITY

- 线性模型是很多机器学习模型的基础，可以用于处理分类、回归以及降维问题。线性模型可以通过联系函数、基函数以及核函数方法，实现非线性推广，构成非线性分类器或回归器
- 对数几率回归LR、线性判别分析LDA的模型设计思想、学习策略、优化方法要认真学习、对比以及实验



Logistic回归 (LR)



线性判别分析 (LDA)



武漢大學
WUHAN UNIVERSITY

End of This Part
