

机器学习第二次作业

1. AdaBoost 权重更新与样本分布变化

给定一个二分类数据集：

样本	x_i	标签 y_i
1	A	+1
2	B	+1
3	C	-1
4	D	-1

第一个弱分类器 $h_1(x)$ 的预测如下：

样本	$h_1(x_i)$
A	+1
B	-1
C	-1
D	+1

已知错误率 $\varepsilon_1 = 0.25$ 。

(1) 计算弱分类器权重： $\alpha_1 = \frac{1}{2} \ln \frac{1-\varepsilon_1}{\varepsilon_1}$

(2) 计算新的样本分布 $D_2(i)$ 。

(3) 请分析哪些样本的权重会上升？这意味着 AdaBoost 下一轮学习时会偏向哪些样本？解释其原因。

2. Bagging 模型方差与集成优点

某回归问题中，单个基学习器的输出方差为 $\text{Var}(T_i) = 1.2$ ，不同学习器之间的预测相关系数为 $\rho = 0.2$ 。共有 $N = 50$ 个学习器。

- (1) 计算集成预测输出的总体方差： $\text{Var}(\bar{T}) = \rho \text{Var}(T_i) + \frac{1-\rho}{N} \text{Var}(T_i)$
- (2) 若改为 $N = 200$ 个学习器，新的方差是多少？
- (3) 结合计算结果，Bagging 模型减少方差的机制是什么？为何当学习器越多、相关性越低时效果越好？

3. PCA 主成分方向与投影

给定数据集如下，每一行是一条样本：

$$X = \begin{bmatrix} 2 & 0 & 1 \\ 3 & 1 & 2 \\ 4 & 0 & 3 \\ 5 & 2 & 4 \\ 6 & 3 & 5 \end{bmatrix}$$

- (1) 求特征值与特征向量，并将特征向量进行单位化。
- (2) 指出主成分方向，并计算方差贡献率。
- (3) 对样本 $x = [4, 0, 3]^T$ ，计算其在第一主成分上的投影。
- (4) 如果仅保留第一主成分，原始三维信息会损失多少？此损失代表什么含义？

4. 马氏距离及其与欧氏距离比较

设有三维特征空间中的两个样本：

$$x_1 = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad x_2 = \begin{bmatrix} 5 \\ 4 \\ 6 \end{bmatrix}$$

其类内协方差矩阵为：

$$S = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 1 & 2 \end{bmatrix}$$

(1) 计算马氏距离： $d_M(x_1, x_2) = \sqrt{(x_1 - x_2)^T S^{-1} (x_1 - x_2)}$

(2) 同时计算欧氏距离 $d_E(x_1, x_2)$ 。

(3) 比较两种距离的差别：为什么马氏距离能更合理地度量样本间的相似性？它捕捉了数据的什么结构特征？

5. K-Means 聚类迭代与收敛分析

一维数据集：

$$x = \{1, 2, 3, 10, 11, 12\}$$

初始化：

$$\mu_1 = 2, \quad \mu_2 = 10$$

(1) 执行两次完整的 K-Means 迭代，每次写出簇分配与新的中心。

(2) 说明两步后算法是否收敛。

(3) 若初始中心改为 $\mu_1 = 3, \mu_2 = 12$ ，结果会怎样变化？为什么 K-Means 对初始化敏感？

6. 高斯混合模型 (GMM)

有两个一维高斯成分：

成分	权重 π_k	均值 μ_k	方差 σ_k^2
1	0.4	0	1
2	0.6	3	1

给定样本 $x = 1$ 。

(1) 写出每个成分的后验概率（职责）：

$$\gamma_k(x) = \frac{\pi_k \mathcal{N}(x|\mu_k, \sigma_k^2)}{\sum_{j=1}^2 \pi_j \mathcal{N}(x|\mu_j, \sigma_j^2)}$$

并代入数值计算。

(2) 求两成分的责任度比值 $\frac{\gamma_1(x)}{\gamma_2(x)}$ 。

(3) 分析哪个成分对该样本的解释更大？如果两个高斯方差变大，职责会发生什么变化？这说明了 GMM 的哪种鲁棒性问题？