

武汉大学

《云上大数据实验》实验报告

姓 名：刘鼎琨
学 号：2023302121009
专 业：计算机科学与技术
学 院：计算机学院
指导教师：林馥老师

二〇二五年 九月

原创性声明

本人郑重声明：所呈交的论文（设计），是本人在指导教师的指导下，严格按照学校和学院有关规定完成的。除文中已经标明引用的内容外，本论文（设计）不包含任何其他个人或集体已发表及撰写的研究成果。对本论文（设计）做出贡献的个人和集体，均已在文中以明确方式标明。本人承诺在论文（设计）工作过程中没有伪造数据等行为。若在本论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：刘鼎琨

日期： 2025 年 9 月 18 日

摘要

本实验基于华为云平台，完整地搭建了一套 Hadoop 与 Spark 协同工作的分布式大数据处理系统。通过配置弹性云服务器（ECS）集群作为计算资源，并结合对象存储服务（OBS）作为数据存储后端，成功实现并验证了一种灵活、高效的存算分离架构。实验涵盖了从基础环境准备、Hadoop 集群（HDFS、YARN）部署、Spark on YARN 配置，到最终通过 WordCount 应用验证与 OBS 数据无缝对接的全过程。本次实践深入探索了云环境下大数据平台的构建方法，验证了存算分离架构在资源弹性、运维简化和成本控制方面的优势，为掌握云原生大数据技术奠定了坚实的实践基础。

关键词：云计算；存算分离；华为云；Hadoop；Spark

ABSTRACT

This experiment, based on the Huawei Cloud platform, comprehensively constructs a distributed big data processing system featuring the collaboration of Hadoop and Spark. By configuring an Elastic Cloud Server (ECS) cluster as the computational resource and leveraging the Object Storage Service (OBS) as the data storage backend, a flexible and efficient compute-storage separation architecture was successfully implemented and verified. The experiment covered the entire process, from preparing the basic environment, deploying the Hadoop cluster (HDFS, YARN), and configuring Spark on YARN, to finally validating seamless data integration with OBS through a WordCount application. This hands-on practice provides a deep dive into building big data platforms in a cloud environment, demonstrates the advantages of the compute-storage separation architecture in terms of resource elasticity, operational simplification, and cost control, and lays a solid practical foundation for mastering cloud-native big data technologies.

Keywords: Cloud Computing; Compute-Storage Separation; Huawei Cloud; Hadoop; Spark

目 录

原创性声明.....	II
摘 要.....	1
ABSTRACT.....	2
1 实验概述.....	1
1.1 实验目的.....	1
1.2 实验总体思路.....	1
1.3 实验注意事项.....	2
2 实验环境与资源准备.....	3
2.1 弹性云服务器 ECS 创建与配置.....	3
2.2 对象存储服务 OBS 创建与配置.....	4
2.3 访问密钥 AK/SK 获取.....	5
3 Hadoop 集群搭建与验证.....	6
3.1 节点基础环境配置（主机名、互信、JDK 等）.....	6
3.2 Hadoop 核心组件配置（core-site, hdfs-site 等）.....	7
3.3 Hadoop 安装包分发与环境变量配置.....	8
3.4 HDFS 格式化与集群启动.....	8
3.5 集群与 OBS 连通性验证.....	9
4 Spark 集群搭建与存算分离验证.....	11
4.1 Spark 组件部署与分发.....	11
4.2 Spark on YARN 环境配置.....	11
4.3 存算分离 WordCount 实验验证.....	12
5 实验感受与总结.....	14
5.1 实验手册注意事项.....	14
5.2 实验感受.....	14
5.3 实验总结.....	14

1 实验概述

1.1 实验目的

本实验基于华为云平台，旨在搭建一个完整的大数据处理环境，深入理解分布式计算框架 Hadoop 和 Spark 的核心原理与实践部署。通过亲手搭建 Hadoop 和 Spark 集群，并将其与华为云对象存储服务 OBS 相结合，掌握存算分离架构的设计与实现方法。实验将使我系统学习 Hadoop 与 Spark 的集群配置、节点间通信、资源管理以及任务执行全流程，加深对分布式存储与计算协同工作机制的理解，为后续进行大规模数据处理和分析的云上应用开发奠定坚实的技术基础。

1.2 实验总体思路

本实验的核心是基于华为云服务构建一个 Hadoop 与 Spark 协同工作的存算分离大数据平台。整体思路遵循环境准备、Hadoop 集群搭建、Spark 集群搭建和功能验证四个主要阶段。




图 1.1 存算分离架构示意图

如图 1.1 所示，首先在同一个 VPC（虚拟私有云）内准备好多台 ECS（弹性云服务器）实例作为集群节点，并创建一个 OBS（对象存储服务）桶用于统一的数据存储。

第一阶段，搭建 Hadoop 集群。在主节点和从节点上完成基础环境配置，包括设置静态 IP、主机名映射以及节点间的 SSH 免密登录。随后，在所有节点上部署和配置 Hadoop，重点修改 `core-site.xml`、`hdfs-site.xml` 等核心配置文件，定

义文件系统、NameNode 地址和数据副本等参数。特别地，通过集成华为云提供的 OBS 适配包（JAR 包），使 Hadoop 集群能够原生支持以 obs://协议访问对象存储，为后续的存算分离奠定基础。

第二阶段，在 Hadoop 集群之上搭建 Spark 计算框架。部署 Spark 并配置其运行在 YARN 资源管理器之上，通过修改 Spark 的环境配置文件，关联 Hadoop 的配置路径，使得 Spark 能够利用 YARN 进行资源调度。

最后阶段，进行存算分离验证。启动 Hadoop 的 HDFS 和 YARN 服务，然后通过 PySpark 的交互式环境，编写一个 WordCount 程序。该程序直接读取存放在 OBS 桶中的文本文件，执行分布式计算，并将结果输出。通过这一流程验证 Spark 计算集群（部署在 ECS 上）与数据存储（OBS）的成功分离与协同工作。

1.3 实验注意事项

ECS 集群选择鲲鹏 arm 架构时，Hadoop 和 SPark 的依赖库版本可能会有冲突，实操过程中我选择的是 X86 架构的 ECS。同时实验手册中修改 xml 文件时，相应的 amd64 需要修改成 X86 样式，路径上也需要加上/jre 作为 Path。

下载 hadoop-huaweicloud-3.1.1-hw-54.0.jar 包时需要根据手册核对是否正确，否则 Hadoop 服务无法启动。同时下载 hadoop-3.1.1.tar.gz 和 spark-2.3.3-bin-without-hadoop.tgz 这两个包时，网速较慢，可提前在自己电脑本地下载，随后通过 scp 指令传输到 ECS 云主机上，减少等待时间。

2 实验环境与资源准备

2.1 弹性云服务器 ECS 创建与配置

本实验选择华为云弹性云服务器（Elastic Cloud Server, ECS）作为大数据集群的计算节点。根据实验需求，共创建三台 ECS 实例，其中一台作为主节点（Master），另外两台作为从节点（Worker）。

在创建 ECS 实例时，计算架构选择了 X86 规避 Hadoop 和 Spark 的库冲突问题，地域选择了华北-北京四以保证较低的网络延迟。所有实例均选用公共镜像，操作系统为 CentOS 7.6 64bit，该版本系统稳定且兼容性强，适合部署大数据环境。在硬件规格上，主节点和从节点均选用通用型 S6 实例，配置为 8vCPU 与 32GB 内存，以满足集群管理和计算任务的需求。存储方面，每台 ECS 配置了 200GB 的 SSD 系统盘。

如图 2.1 所示，网络配置是确保集群正常通信的关键。所有 ECS 实例均部署在同一虚拟私有云（VPC）和子网下，以实现内部网络的高速互通。主节点配置了弹性公网 IP（EIP）以方便远程管理，而从节点则不配置公网 IP 以增强安全性。安全组规则经过精确设置，开放了 SSH（22 端口）以及 Hadoop、Spark 等服务所需的端口，并允许集群内部所有节点间的相互通信。



图 2.1 ECS 存储与网络配置图

如图 2.2 所示，为便于管理，三台 ECS 实例的主机名与 IP 地址规划如下：主节点命名为 `ecs-xhr-test-0001`，两个从节点分别命名为 `ecs-xhr-test-0002` 和 `ecs-xhr-test-0003`。实例创建完成后，通过 SSH 远程登录并修改各节点的 `/etc/hosts` 文件，完成了 IP 地址与主机名的静态映射，为后续集群配置奠定了基础。




图 2.2 ECS 集群图

2.2 对象存储服务 OBS 创建与配置

对象存储服务（Object Storage Service, OBS）是实现本实验存算分离架构的核心，为大数据集群提供统一、高可靠的数据存储后端。实验中创建了一个 OBS 桶，用于存放待处理的原始数据和计算后的结果数据。

在华为云控制台进入 OBS 服务页面，创建一个新的 OBS 桶。如图 2.3 所示，配置过程中，区域选择与之前创建的 ECS 实例所在的同一区域，以确保 ECS 与 OBS 之间通过内网进行数据交互，从而获得最佳的访问性能和最低的数据传输成本。桶名称需设置为全局唯一的字符串。存储类别选择“标准存储”，该类别适用于频繁访问的数据场景，满足大数据处理的需求。桶的访问权限设置为“私有”，确保数据安全，后续通过配置访问密钥（AK/SK）的方式授予 Hadoop 集群访问权限。创建完成后，记录下该 OBS 桶的名称和 Endpoint（访问域名），这些信息将在配置 Hadoop 集群时使用。



图 2.3 OBS 桶配置图

2.3 访问密钥 AK/SK 获取

为了让 Hadoop 集群能够以编程方式安全地访问 OBS 桶中的数据，需要创建并使用访问密钥（Access Key ID/Secret Access Key, AK/SK）。AK/SK 是华为云为用户提供的一种身份验证凭证，用于 API 调用和各类服务的集成。

获取过程在华为云控制台的“我的凭证”页面中进行。在凭证管理界面，选择“访问密钥”标签页，点击“新增访问密钥”按钮。系统会进行身份验证，验证通过后即可成功创建一个新的密钥对。创建成功后，系统会提示立即下载包含 AK 和 SK 信息的 credentials.csv 文件。此文件是唯一一次获取完整 SK 的机会，因此必须立即下载并妥善保管。获取到的 AK 和 SK 将作为关键配置信息，在后续配置 Hadoop 的 core-site.xml 文件时填入，从而完成 Hadoop 与 OBS 服务的认证对接。

3 Hadoop 集群搭建与验证

3.1 节点基础环境配置（主机名、互信、JDK 等）

Hadoop 集群的稳定运行依赖于一个统一且配置正确的基础环境。如图 3.1 所示，首先下载 `hadoop-3.1.1.tar.gz` 包，该步骤下载较慢，可以在本地提前下载。在所有 ECS 节点上，首先需确保主机名与 IP 地址的正确解析。如图 3.2 所示，通过修改每个节点的 `/etc/hostname` 文件来设定其主机名，并统一在所有节点的 `/etc/hosts` 文件中添加所有集群成员的 IP 地址与主机名映射关系。此举确保了集群各组件之间可以通过主机名进行通信，而不是直接依赖可能变动的 IP 地址。




图 3.1 hadoop-3.1.1.tar.gz 包下载图

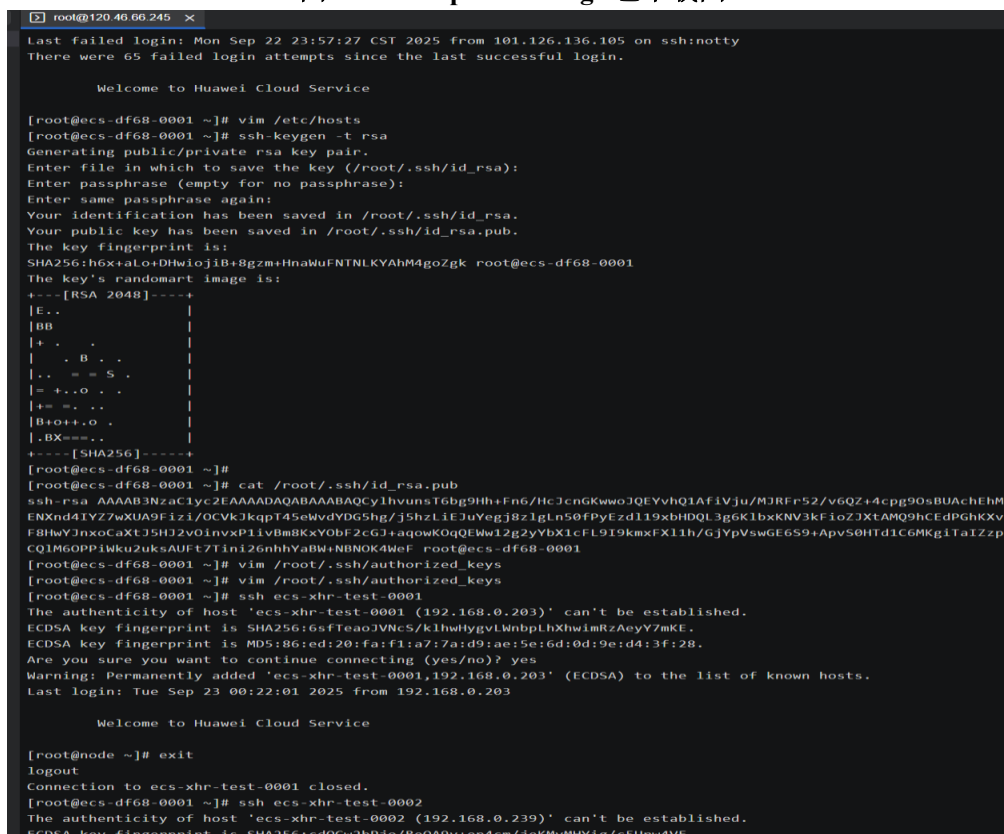


图 3.2 ECS 集群映射配置图

接下来，为实现主节点对从节点的统一管理和脚本的批量执行，必须配置节点间的 SSH 免密登录。在主节点上使用 `ssh-keygen` 命令生成一对 RSA 密钥（公钥和私钥），然后将生成的公钥（通常是 `~/.ssh/id_rsa.pub` 文件）内容追加到所有节点（包括主节点自身）的 `~/.ssh/authorized_keys` 文件中。配置完成后，从主节点可以无密码 SSH 登录到任意一个从节点，为后续一键启动和停止集群服务提供了便利。

最后，由于 Hadoop 和 Spark 是基于 Java 开发的，必须在所有节点上安装和配置统一的 Java 运行环境（JDK）。本实验要求使用 JDK 1.8 版本。通过在各节点执行 `java -version` 命令检查 JDK 是否已安装及版本是否正确。若未安装，则使用系统的包管理器（如 `yum`）进行安装。安装完成后，配置系统环境变量，设置 `JAVA_HOME` 指向 JDK 的安装路径，并将 `$JAVA_HOME/bin` 添加到 `PATH` 变量中，以确保 Java 命令在任何路径下都可被系统识别。

3.2 Hadoop 核心组件配置（`core-site`, `hdfs-site` 等）

基础环境就绪后，需在主节点上对 Hadoop 的核心配置文件进行修改，以定义集群的运行模式和各项关键参数。这些配置文件均位于 Hadoop 安装目录下的 `etc/hadoop/` 中。

首先配置 `core-site.xml` 文件，此文件是集群的核心配置，定义了文件系统的类型和 Hadoop 的临时目录等。关键在于配置与 OBS 的连接参数，包括将 `fs.obs.impl` 指定为华为云提供的 OBS 文件系统实现类，并填入之前获取的 `fs.obs.access.key`、`fs.obs.secret.key` 以及 OBS 桶的 `fs.obs.endpoint`。同时，将 `fs.defaultFS` 参数指向 HDFS 的 NameNode 地址，即主节点的地址，从而确立了集群的默认文件系统。

接着配置 `hdfs-site.xml`，该文件用于定义 HDFS 的具体参数。在这里主要设置了数据块的副本数量 `dfs.replication`，根据集群规模（两个从节点）将其设置为 2，以保证数据的冗余备份。此外，还指定了 Secondary NameNode 的 HTTP 访问地址。

然后配置 `yarn-site.xml`，用于定义 YARN 资源管理框架的行为。其中，`yarn.resourcemanager.hostname` 参数被明确设置为主节点的主机名，指定其作为

集群的资源管理器。同时，通过 `yarn.nodemanager.aux-services` 启用了 MapReduce 任务所需的 `mapreduce_shuffle` 服务。

最后，配置 `mapred-site.xml` 和 `slaves` 文件。在 `mapred-site.xml` 中，将 `mapreduce.framework.name` 的值设置为 `yarn`，表明 MapReduce 任务将运行在 YARN 框架之上。在 `slaves` 文件中，则列出了所有从节点的主机名，告知主节点哪些机器将作为 `DataNode` 和 `NodeManager`。

3.3 Hadoop 安装包分发与环境变量配置

在主节点上完成所有配置文件的修改后，为了确保整个集群环境的一致性，必须将配置好的 Hadoop 安装目录完整地分发到所有的从节点。这一步利用了之前配置好的 SSH 免密登录，通过 `scp` (Secure Copy) 命令实现。从主节点执行 `scp -r` 命令，将整个 Hadoop 目录远程复制到每个从节点的相同路径下。此操作保证了所有节点上的 Hadoop 版本、配置文件内容以及目录结构完全一致，这是集群能够协同工作的前提。

为了让系统能够识别 Hadoop 和 Java 的相关命令，还需要在集群的每一个节点上配置全局环境变量。通过编辑 `/etc/profile` 文件，添加 `HADOOP_HOME` 和 `JAVA_HOME` 两个环境变量，分别指向 Hadoop 和 JDK 的安装根目录。同时，需要将 `$HADOOP_HOME/bin`、`$HADOOP_HOME/sbin` 以及 `$JAVA_HOME/bin` 追加到系统的 `PATH` 变量中。完成修改后，在每个节点上执行 `source /etc/profile` 命令使配置立即生效。这样，用户就可以在任何目录下直接执行如 `hdfs`、`yarn` 等 Hadoop 命令，极大地方便了集群的管理和使用。

3.4 HDFS 格式化与集群启动

在首次启动 HDFS 之前，必须对其进行格式化操作。这是一个初始化步骤，用于在 `NameNode` 上创建文件系统的元数据存储结构。此操作仅在主节点上执行一次，切勿重复执行，否则会导致 HDFS 中所有数据丢失。在主节点上，执行 `hdfs namenode -format` 命令。看到 “Storage directory ... has been successfully formatted” 的提示信息后，即表示格式化成功完成。

如图 3.3 所示，格式化成功后，便可以启动整个 Hadoop 集群。Hadoop 提供了一键式脚本来启动所有服务，极大简化了操作。在主节点上，首先执行 start-dfs.sh 脚本来启动 HDFS 服务，该脚本会自动启动主节点上的 NameNode 和从节点上的所有 DataNode。随后，执行 start-yarn.sh 脚本来启动 YARN 服务，这将启动主节点上的 ResourceManager 和从节点上的所有 NodeManager。




图 3.3 HDFS 服务启动图

为了验证集群是否成功启动，可以在各个节点上使用 jps (Java Virtual Machine Process Status Tool) 命令来查看正在运行的 Java 进程。在主节点上，应能看到 NameNode、ResourceManager 和 SecondaryNameNode 等进程；在每个从节点上，则应能看到 DataNode 和 NodeManager 进程。确认所有核心进程均已正常启动，标志着 Hadoop 集群已准备就绪。

3.5 集群与 OBS 连通性验证

Hadoop 集群成功启动后，必须验证其与对象存储服务 OBS 的连通性，这是确保存算分离架构正常工作的关键一步。该验证旨在确认 core-site.xml 中配置的 AK/SK、Endpoint 以及 OBS 适配 JAR 包均已正确生效。

如图 3.4 所示，为进行验证，首先通过华为云 OBS 控制台，在之前创建的存

储桶中手动上传一个测试文件（一个简单的文本文件）。这一步是为了确保 OBS 中存在可供查询的对象。




图 3.4 创建测试文件图

验证操作在 Hadoop 主节点上通过执行 `hdfs dfs` 命令完成。由于在配置文件中已正确声明了 OBS 的文件系统实现，Hadoop 的命令行工具能够直接识别并操作以 `obs://` 协议开头的路径。在主节点上执行 `hdfs dfs -ls obs://<桶名称>/` 命令，其中 `<桶名称>` 替换为实际创建的 OBS 桶名。

如图 3.5 所示，如果命令执行后，终端能成功列出 OBS 桶内所有对象（包括刚刚上传的测试文件），则表明 Hadoop 集群与 OBS 服务之间的认证和数据通路已完全打通。这一结果确认了存算分离架构中“存”的部分已配置无误，为后续 Spark 计算任务直接读写 OBS 数据奠定了基础。




图 3.4 Hadoop 与 OBS 联通验证图

4 Spark 集群搭建与存算分离验证

4.1 Spark 组件部署与分发

在 Hadoop 集群正常运行的基础上，开始部署 Spark 计算框架。首先在主节点上进行 Spark 的下载和初步配置。通过 `wget` 命令从 Apache 官网下载预编译的 Spark 版本，本实验选择不包含 Hadoop 依赖的 `without-hadoop` 版本，以便复用已部署的 Hadoop 集群环境，避免版本冲突。下载完成后，使用 `tar` 命令将安装包解压到指定目录。

为了让 Spark 能够与 OBS 进行交互，实现数据的直接读写，需要将之前 Hadoop 配置中使用的 OBS 适配 JAR 包复制到 Spark 安装目录下的 `jars` 子目录中。这一关键步骤使得 Spark 的执行环境能够加载到访问 OBS 所需的驱动和类库。

完成主节点上的部署后，与 Hadoop 类似，需要将配置好的 Spark 安装目录分发到所有的从节点。利用 `scp -r` 命令将整个 Spark 目录从主节点复制到所有从节点的相同路径下，确保整个集群拥有统一的 Spark 运行环境和依赖。

4.2 Spark on YARN 环境配置

为了使 Spark 能够作为 YARN 的客户端提交应用，并由 YARN 负责其资源调度，必须进行相应的环境配置，核心是让 Spark 能够找到并读取 Hadoop 的配置文件。

配置工作在主节点上进行。首先，进入 Spark 安装目录下的 `conf` 子目录，将配置文件模板 `spark-env.sh.template` 复制为 `spark-env.sh`。然后，编辑 `spark-env.sh` 文件，在其中添加关键的环境变量。最重要的一项是设置 `HADOOP_CONF_DIR`，将其路径指向 Hadoop 配置文件的存放目录（即 `$HADOOP_HOME/etc/hadoop`）。通过此项配置，Spark 在启动时能够自动加载 Hadoop 的 `core-site.xml` 和 `yarn-site.xml` 等文件，从而获知 YARN ResourceManager 的地址和 HDFS 的信息。

为确保 Spark 命令能够在系统中被方便地调用，还需在所有节点上配置全局环境变量。通过编辑 `/etc/profile` 文件，添加 `SPARK_HOME` 变量指向 Spark 的安装目录，并将其 `bin` 目录加入到系统的 `PATH` 变量中。配置完成后，在每个节点上执行 `source /etc/profile` 命令使环境变量生效。至此，Spark on YARN 的运行环

境已配置完毕，集群具备了通过 YARN 来调度和执行 Spark 任务的能力。

4.3 存算分离 WordCount 实验验证

为最终检验整个大数据平台的搭建成果，特别是验证 Spark 计算集群与 OBS 对象存储之间的存算分离架构是否成功实现，本实验设计了一个经典的 WordCount（词频统计）任务。

实验验证前需进行准备工作。首先，确保 Hadoop 的 YARN 服务已在集群中正常启动。其次，将一份用于词频统计的样本文本文档（playerinfo.txt）上传至之前创建的 OBS 桶的根目录下，作为 Spark 任务的数据输入源。

验证操作在主节点上进行。通过在命令行输入 `pyspark`，启动一个交互式的 Python Spark Shell。由于环境已配置为 Spark on YARN 模式，该 Shell 会自动连接到 YARN 集群，并将后续计算任务提交给 YARN 进行调度。

在 PySpark Shell 中，编写并执行相应的代码。首先，通过 `spark.read.text()` 方法读取存放在 OBS 中的 `playerinfo.txt` 文件，其路径格式为 `obs://<桶名称>/playerinfo.txt`。接着，利用 Spark RDD 提供的一系列转换算子（如 `flatMap`, `map`, `reduceByKey`）对文本内容进行分词、映射和聚合操作，完成词频统计。最后，调用 `collect()` 动作算子将计算结果从集群的 Executor 节点收集回 Driver 端（即 PySpark Shell），并遍历打印输出每个单词及其出现的次数。

如图 4.1 所示，当终端成功打印出样本文档中所有单词的正确词频统计结果时，即表明本次实验圆满成功。这一结果有力地证明了：Spark 计算任务能够脱离 HDFS，直接、高效地读写远端的 OBS 数据；同时，任务的分布式执行完全由 YARN 集群负责资源调度和管理。这标志着一个计算与存储相分离、灵活可扩展的云大数据处理平台已成功搭建并投入运行。

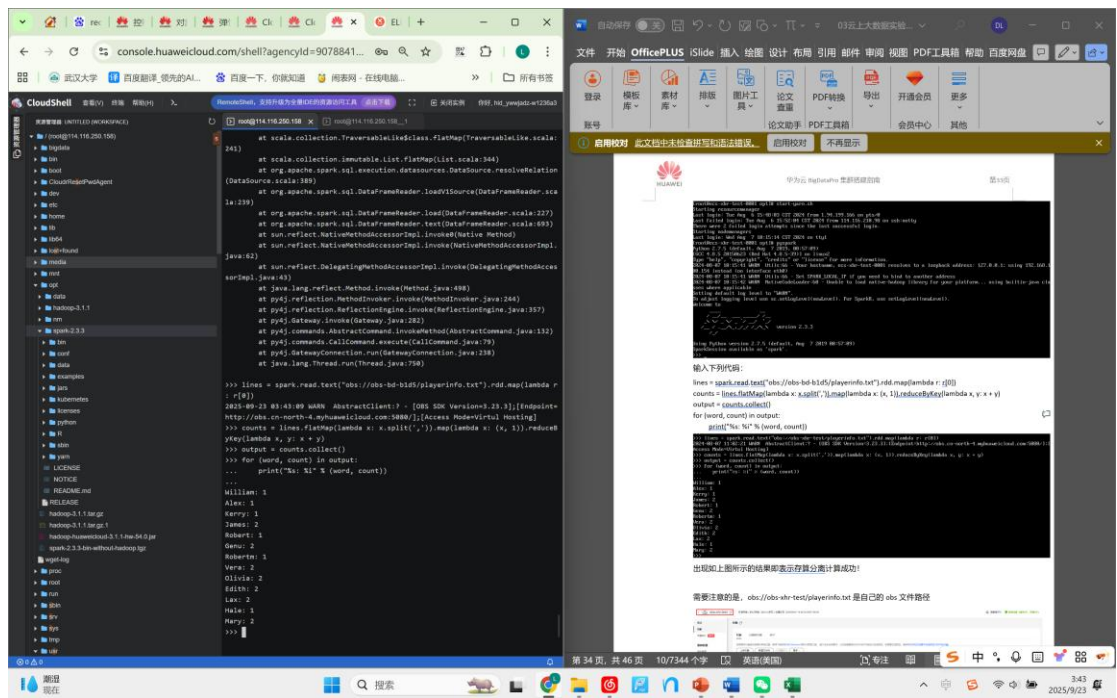


图 4.1 WorkCount 功能验证图

至此，整个大数据平台已经搭建完成，本次实验的花费如图 4.2 所示（包含前两次实验）。




图 4.2 实验花费图

5 实验感受与总结

5.1 实验手册注意事项

以下几条为我实验中发现实验手册上的不足之处：

1. 有一个概念在手册中没有明确说明（虽然指令是正确的），就是关于主机名（hostname）和机器名可能不一致的情况。hostname 指令可以查询到的是机器名，但在某些情况下，如果实验环境没有严格按照文档标准化配置，这二者可能会不相同，需要在配置过程中仔细辨别和确认，避免因名称不一致导致的服务间通信问题。

2. 下载的软件包版本与当时文档中描述的不尽相同。例如，在我下载的软件包路径中，可能需要额外加上/jre 作为\$PATH 环境变量的一部分，才能正确识别和执行相关的 Java 程序。这种版本差异和路径配置细节在文档中未详细说明，需要实验者进行额外的探索和调整。

5.2 实验感受

本次实验操作（步骤）做下来很容易，主要是按照指导进行配置、搭建集群。然而，如果要深入理解配置中的各种参数的含义和作用，就变得非常困难了。这说明实验在执行层面流程清晰，但在理论深度和底层原理解释方面可能有所欠缺。对于大数据组件（如 Hadoop、Spark）的众多配置文件和参数，若没有深入理解，虽然能完成搭建，但难以针对具体场景进行优化或排查复杂问题。

5.3 实验总结

本次《云上大数据实验》旨在利用云平台的技术优势，搭建并验证一个具备存算分离架构的分布式大数据处理系统。实验基于华为云平台，成功地构建了 Hadoop 和 Spark 协同工作的分布式环境，并以 WordCount 应用为例，验证了其功能和性能。主要内容有三。

环境准备与资源配置： 在华为云上成功创建并配置了弹性云服务器（ECS）作为计算节点，并创建了对象存储服务（OBS）作为数据存储后端，同时获取了访问密钥（AK/SK）以确保服务间的安全访问。

Hadoop 集群搭建与验证： 按照实验手册完成了 Hadoop 集群的各项基础环境配置（如主机名、SSH 互信、JDK 安装等），并配置了 Hadoop 核心组件（core-site.xml, hdfs-site.xml 等）。成功格式化 HDFS 并启动了 Hadoop 集群，验证了集群的正常运行以及 HDFS 与 OBS 的连通性。

Spark 集群搭建与存算分离验证： 在 Hadoop 集群的基础上，部署并分发了 Spark 组件，配置了 Spark on YARN 环境。最终，通过经典的 WordCount 程序，成功验证了计算与存储分离的架构，即 Spark 在 ECS 集群上进行计算，数据则从 OBS 中读取，计算结果也可以写入 OBS。这充分展示了存算分离架构的灵活性和高效性。