

向量是现代 AI 的基石。向量化通过嵌入模型将文本、图像、音频等非结构化数据映射为高维空间中的向量,使语义信息转化为可被距离度量的几何位置关系;向量索引采用近邻图、倒排文件等途径支持高效的近似最近邻搜索,实现语义向量的毫秒级检索;而向量压缩技术则通过子空间划分和码本映射将单条向量的大小从数千字节压缩至数十字节,在有限内存中支撑十亿级规模的检索。围绕语义向量的存储、索引、检索等技术构成了现代向量数据库与检索增强生成(RAG)体系的技术底座。

下面是向量数据管理领域值得讨论的话题:

1. 数据的向量化: 还有哪些数据是目前难以被向量化的? 难在哪里? 领域里目前有哪些进展?
2. 向量的近邻搜索: 在各种新式硬件(SSD、GPU 等)如何支持向量的近邻搜索? 有哪些代表性方法?
3. 其他的向量查询需求: 除了近邻查询, 目前还有哪些主要的查询需求和代表性解决方案?
4. 向量索引的动态更新: 哪些索引能够支持向量的高效增加、删除或修改?
5. 向量数据库: 向量数据库的商业化未来会走向何方? 原生向量数据库的优势是否不可取代? 拓展式数据库提供的向量检索能力是否真实可信?
6. 向量搜索的应用: RAG 目前有哪些前沿进展?

请选择适当的话题,调研国内外前沿进展,运用计算思维和问题求解思维,形成课程结题报告,题目自拟。要求:

1. 课程结题报告应列出主要的参考文献。
2. 鼓励使用 AI 整理思路、搜索素材和润色语言,但应确保 AI 生成的内容(包括文字、数据、图、表、参考文献等)符合你的真实表达意愿,并在课程报告中注明 AI 的使用方式和范围。
3. 鼓励小组合作、共同探究,但课程结题报告应独立完成,并注明小组合作者的贡献。